



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática



**TFG del Grado en Ingeniería
Informática**

**Análisis de temas en Trabajos
Fin de Grado**



Presentado por Zeldan Javier Campos Cordero
en Universidad de Burgos — 23 de noviembre
de 2025

Tutor: Carlos López Nozal



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática



D. Carlos López Nozal, profesor del departamento de Ingeniería Informática, área de Lenguajes y Sistemas Informáticos.

Expone:

Que el alumno D. Zeldan Javier Campos Cordero, con DNI 55462889E, ha realizado el Trabajo final de Grado en Ingeniería Informática titulado Análisis de temas en Trabajos Fin de Grado.

Y que dicho trabajo ha sido realizado por el alumno bajo la dirección del que suscribe, en virtud de lo cual se autoriza su presentación y defensa.

En Burgos, 23 de noviembre de 2025

Vº. Bº. del Tutor:

D. Carlos López Nozal

Resumen

TFG topics es una aplicación que pretende realizar análisis temáticos cualitativos de los textos contenidos en las memorias de los trabajos finales de grado (TFG). Su objetivo es desarrollar una herramienta que permita a los docentes y estudiantes explorar e identificar tendencias en el contenido académico de dichos trabajos.

Para ello, se parte de un conjunto de datos creado con las memorias de TFG en formato LaTeX disponibles públicamente en GitHub. Sobre estos textos se lleva a cabo el procesamiento y modelado de temas utilizando diversos algoritmos como: **Latent Dirichlet Allocation (LDA)**, **Top2Vec**, **BERTopic** y **FASTopic**.

Este trabajo se centra en la implementación, comparación y evaluación de diferentes algoritmos de modelado de temas (**Topic Modeling**), con el fin de construir una herramienta que ayude a la gestión del conocimiento académico en el ámbito universitario.

Descriptores

Análisis temático, Topic Modeling, LDA, BERTopic, Top2Vec, FASTopic, TFG, Análisis de Datos, Procesamiento del Lenguaje Natural, Ingeniería Informática.

Abstract

TFG Topic is an application designed to perform qualitative thematic analysis of the texts contained in Bachelor's Thesis (TFG) reports. Its main goal is to develop a tool that enables teachers and students to explore and identify trends within the academic content of these works.

To achieve this, a dataset was built from TFG reports written in LaTeX format and publicly available on GitHub. These texts are processed and analyzed using various topic modeling algorithms, such as **Latent Dirichlet Allocation (LDA)**, **Top2Vec**, **BERTopic**, and **FASTopic**.

This work focuses on the implementation, comparison, and evaluation of different **Topic Modeling** algorithms, with the aim of building a tool that supports academic knowledge management within the university context.

Keywords

Topic Modeling, LDA, BERTopic, Top2Vec, FASTopic, TFG, Data Analysis, PNL, Computer Science.

Índice general

Índice general	iii
Índice de figuras	iv
Índice de tablas	v
1. Introducción	1
2. Objetivos del proyecto	3
2.1. Objetivo general	3
2.2. Objetivos específicos	3
2.3. Objetivos personales	4
3. Conceptos teóricos	5
3.1. Procesamiento de lenguaje natural	5
3.2. Representación del texto	6
3.3. Modelado de temas	6
3.4. Evaluación de modelos	8
4. Técnicas y herramientas	9
5. Aspectos relevantes del desarrollo del proyecto	11
6. Trabajos relacionados	13
7. Conclusiones y Líneas de trabajo futuras	15
Bibliografía	17

Índice de figuras

Índice de tablas

1. Introducción

En el ámbito universitario anualmente se generan gran cantidad de documentos académicos que proporcionan una valiosa fuente de información. Especialmente las memorias de los **Trabajos de Fin de grado (TFG)** que poseen un alto valor y que forman parte fundamental del proceso formativo del estudiante, ya que permiten aplicar los conocimientos adquiridos durante la realización de los estudios de grado. Estas memorias contienen información sobre tendencias tecnológicas actuales, herramientas y investigaciones realizadas sobre distintas áreas de la informática. Sin embargo, resulta muy laborioso ubicar y extraer esta información ya que encuentra almacenada de manera dispersa en distinto repositorios y formatos.

Este trabajo tiene como finalidad el desarrollo de una aplicación para el análisis cualitativo de los textos contenidos en las memorias de TFG del grado en ingeniería Informática de la Universidad de Brugos. Esta herramienta permite el análisis, consulta, facilita la exploración, calculo de tendencias y comparación de trabajos a lo largo del tiempo partiendo de estos contenidos textuales. El conjunto de datos analizado se encuentra en formato $\text{\LaTeX}$ y se encuentra disponible en plataformas como GitHub, a estos datos se le aplicaran técnicas de modelado de temas utilizando distintos algoritmos de última generación, entre ellos **Latent Dirichlet Allocation (LDA)**, **Top2Vec**, **BERTopic** y **FASTopic**.

La aplicación resultante servirá como ayuda a la comunidad docente, investigadora e estudiantil para la exploración de la información académica. Además, se busca poner en práctica los conocimientos adquiridos y competencias durante la titulación.

Este proyecto se fundamenta en el uso de técnicas de modelado de temas. El modelado de temas es una tarea de aprendizaje no supervisado donde

se identifica la estructura temática de un grupo de documentos. Al utilizar estas técnicas es posible encontrar temas relevantes para organizar, buscar o comprender grandes cantidades de datos en formato de texto. Estos modelos se basan en el supuesto de cada documento puede explicarse como una mezcla de temas, donde cada tema es un grupo de términos que poseen una distribución de potabilidades.

Esta memoria se estructura de la siguiente manera: **Introducción**, se realiza una descripción inicial de el trabajo y su estructura; **Objetivos**, descripción de los objetivos generales y específicos que se pretenden alcanzar con la elaboración de este proyecto; **Conceptos teóricos**, en esta sección se presenta el marco teórico y conceptual que fundamenta el modelado de temas; **Técnicas y herramientas**, se describen las técnicas y herramientas utilizadas para la elaboración de la aplicación; **Aspectos relevantes del desarrollo del proyecto**, se presentan los desafíos superados durante la realización del proyecto, la metodología seguida y el diseño del sistema; **Trabajos relacionados**, se exponen otros proyectos y aplicaciones similares y se realizar una comparación con el proyecto actual; **Conclusiones y lineas de trabajo futura**, los resultados obtenidos y su análisis comparativo y se detallan las conclusiones y las posibles líneas de trabajo futuro.

2. Objetivos del proyecto

El presente Trabajo Fin de Grado tiene como objetivo principal el desarrollo de una aplicación capaz de realizar análisis temáticos cualitativos sobre los textos contenidos en las memorias de los Trabajos Fin de Grado (TFG) en Ingeniería Informática. Este proyecto busca aplicar técnicas de procesamiento del lenguaje natural (NLP) y modelado de temas (*Topic Modeling*) para facilitar la identificación de tendencias, temas recurrentes y áreas de investigación dentro del ámbito académico.

2.1. Objetivo general

Diseñar e implementar una aplicación que permita realizar análisis temáticos automáticos sobre memorias de TFG, utilizando diversos algoritmos de modelado de temas y evaluando su rendimiento en términos de coherencia y eficiencia.

2.2. Objetivos específicos

Para alcanzar el objetivo general, se plantean los siguientes objetivos específicos:

- **Recopilar y preparar los datos:** Crear un conjunto de datos a partir de memorias de TFG en formato $\text{\LaTeX}$ disponibles públicamente en GitHub, realizando el preprocesamiento necesario de los textos.
- **Implementar diferentes algoritmos de modelado de temas:** Investigar, aplicar y comparar métodos como **Latent Dirichlet Allocation (LDA)**, **Top2Vec**, **BERTopic** y **FASTopic**.

- **Evaluar el rendimiento de los modelos:** Medir y comparar la calidad de los temas generados utilizando métricas de coherencia temática.
- **Desarrollar una interfaz visual:** Diseñar una aplicación que permita la visualización de los resultados obtenidos.
- **Fomentar la gestión del conocimiento académico:** Promover el acceso y la reutilización del conocimiento generado por estudiantes en cursos anteriores, apoyando la investigación y la docencia.
- **Diseño de Arquitectura:** Diseñar e implementar una arquitectura de software modular que separe el motor de análisis de la capa de servicio, demostrando principios de Ingeniería de Software.
- **Gestión:** Utilizar herramientas y metodologías ágiles para planificar y implementar el proyecto. Utilizando Zube.io y GitHub.

2.3. Objetivos personales

- Crear una herramienta que sea de utilidad para la comunidad universitaria.
- Aplicar conocimientos adquiridos durante el grado, especialmente en el ámbito de Algoritmia, Desarrollo Avanzado de Sistemas Software y Minería de Datos.
- Consolidar conocimientos en las siguientes tecnologías: Python, git, docker.
- Mejorar habilidades de diseño de software, aplicación de buenas prácticas en desarrollo, testing de software y documentación.

3. Conceptos teóricos

A continuación se exponen conceptos teóricos que sientan las bases del proyecto, cubriendo desde el pre-procesamiento de texto hasta los algoritmos avanzados de modelado.

3.1. Procesamiento de lenguaje natural

El procesamiento de lenguaje natural (PLN, del inglés *Natural Language Processing*, NLP) es un campo de la Inteligencia Artificial (IA, del inglés *Artificial Intelligence*, AI) que se ocupa del análisis y la interpretación de textos que se encuentran en lenguaje humano. Utilizando estas técnicas los computadores pueden dar sentido a los datos contenidos en un conjunto de textos y así adquirir su conocimiento implícito [1].

NLP usa gran variedad de técnicas y modelos para analizar diferentes aspectos de los textos como la formación de palabras, el léxico, la sintaxis entre otros, con esto se pretende resolver problemas específicos relacionados con el lenguaje.

Entre las tareas más comunes del NLP se encuentran la tokenización, lematización, eliminación de palabras vacías (*stopwords*), análisis sintáctico y extracción de información. En el contexto de este trabajo, las técnicas de NLP se utilizan para preparar los textos de las memorias de TFG, transformándolos en datos estructurados que puedan ser analizados mediante algoritmos de modelado de temas.

3.2. Representación del texto

Bolsa de palabras

La bolsa de palabras (del ingles *Bag of Words*, BoW) es una de las técnicas de representación de texto utilizada por distintas aplicaciones de NLP. Esta representación se basa en el conteo de palabras, ignorando el orden y la estructura gramatical del texto.

Representaciones vectoriales

Los embeddings son una técnica de procesamiento de lenguaje natural que convierte el lenguaje humano en vectores matemáticos. Estos vectores son una representación del significado subyacente de las palabras, lo que permite que las computadoras procesen el lenguaje de manera más efectiva [4].

3.3. Modelado de temas

El modelado de temas (*Topic Modeling*) es una técnica muy utilizada con la cual podemos encontrar temas subyacentes dentro de un grupo de documentos que deseemos analizar. Esta sigue un enfoque estadístico y proporciona una forma de representar textos de una manera estructurada, lo que la hace ideal para analizar grandes conjuntos de datos textuales [3].

Dependiendo del algoritmo utilizado los términos se pueden obtener utilizando distintos enfoques como la bolsa de palabras (*Bag of words*), frecuencia de términos, frecuencia inversa de términos o basado en clases [7].

Podemos destacar la importancia del modelado de temas en los siguientes aspectos [3]:

Organización de la información permite categorizar los documentos en temas lo cual hace mas fácil el proceso de búsqueda.

Resumen permite capturar la esencia de la temática del documento.

Recomendación facilita realizar recomendaciones personalizadas para cada usuario usuarios

En este TFG nos centraremos en el uso de los siguiente modelos:

- Latent Dirichlet Allocation

- Top2Vec
- BERTopic
- FASTopic

Latent Dirichlet Allocation (LDA)

LDA (*Latent Dirichlet Allocation*) es un modelo probabilístico que usa matrices de factorización basado en la distribución de Dirichlet. En este modelo se asume que cada documento expone una serie de temas y cada tema se caracteriza por una distribución de palabras basada en la frecuencia de aparición en el documento. Los resultados obtenidos al ejecutar el modelo no son deterministas, por lo que se puede obtener un resultado distinto en cada ejecución para el mismo *dataset* [7, 3].

LDA posee dos parámetros [2] que debemos ajustar para mejorar los resultados obtenidos:

- Numero de temas
- Factor de densidad del documento-tema
- Factor de densidad tema-palabra

Top2Vec

Top2Vec es un algoritmo de modelado de temas basado en *embeddings*, documentos y vectores de palabras. Este algoritmo asume que la semántica interna de los documentos es indicativo de que existe una temática común [5].

BERTopic

BERTopic es un modelo que se basa en el uso de BERT preentrenado para generar representaciones vectoriales de los documentos y temas. El funcionamiento de BERTopic se apoya en dos fases: la codificación de los documentos y el modelado de temas. En la primera etapa, cada texto se transforma en un vector mediante BERT. Posteriormente, se emplea el algoritmo HDBSCAN para agrupar estos vectores y así identificar los distintos temas. A partir de cada grupo, es posible extraer las palabras clave que describen su contenido [6].

La principal ventaja de BERTopic es su capacidad para encontrar matices semánticos y manejar grandes volúmenes de información textual. Puede identificar significados complejos y relaciones contextuales con mayor precisión. Además, a diferencia de otros métodos, no es necesario fijar de antemano cuántos temas se generarán, ya que el algoritmo de clustering determina este número automáticamente [6].

FASTopic

FASTopic (*Fast, Adaptive, Stable and Transferable topic model*). Es un modelo que sigue el enfoque denominado DSR (Reconstrucción de Relaciones Semánticas Dual), este no utiliza redes neuronales y se basa en tres elementos: la representación vectorial de los documentos graneados por un transformador predeterminado, los vectores de temas y de palabras [8].

DSR captura dos tipos de relaciones semánticas: entre documentos y temas, y entre temas y palabras, interpretándolas como distribuciones que permiten descubrir los temas de manera ordenada y eficiente, eliminando la necesidad de estructuras complicadas. Para modelar estas relaciones, se propone además el *Embedding Transport Plan* (ETP), un mecanismo novedoso que, en lugar de emplear funciones *softmax* parametrizadas, regula estas relaciones como planes de transporte óptimo entre los *embeddings* de documentos, temas y palabras. Esto reduce el sesgo en las relaciones y permite obtener temas bien diferenciados y distribuciones más precisas [8].

3.4. Evaluación de modelos

Para evaluar el desempeño de estos modelos podemos seguir las siguiente métricas:

Coherencia evalúa que tan relacionada están, en términos de semántica las palabras mas representativas de un tema. Esta métrica permite identificar cuantos temas son adecuados para un conjunto de datos determinado.

Perplejidad valora el rendimiento del los modelos como LDA. Indica que tan bien el modelo es capaz de predecir documentos no vistos. Cuanto mas baja mejor se considera el desempeño del modelo, implica que el modelo tiene una mayor capacidad para anticipar las palabras de textos que no han sido utilizados durante el entrenamiento.

4. Técnicas y herramientas

Esta parte de la memoria tiene como objetivo presentar las técnicas metodológicas y las herramientas de desarrollo que se han utilizado para llevar a cabo el proyecto. Si se han estudiado diferentes alternativas de metodologías, herramientas, bibliotecas se puede hacer un resumen de los aspectos más destacados de cada alternativa, incluyendo comparativas entre las distintas opciones y una justificación de las elecciones realizadas. No se pretende que este apartado se convierta en un capítulo de un libro dedicado a cada una de las alternativas, sino comentar los aspectos más destacados de cada opción, con un repaso somero a los fundamentos esenciales y referencias bibliográficas para que el lector pueda ampliar su conocimiento sobre el tema.

5. Aspectos relevantes del desarrollo del proyecto

Este apartado pretende recoger los aspectos más interesantes del desarrollo del proyecto, comentados por los autores del mismo. Debe incluir desde la exposición del ciclo de vida utilizado, hasta los detalles de mayor relevancia de las fases de análisis, diseño e implementación. Se busca que no sea una mera operación de copiar y pegar diagramas y extractos del código fuente, sino que realmente se justifiquen los caminos de solución que se han tomado, especialmente aquellos que no sean triviales. Puede ser el lugar más adecuado para documentar los aspectos más interesantes del diseño y de la implementación, con un mayor hincapié en aspectos tales como el tipo de arquitectura elegido, los índices de las tablas de la base de datos, normalización y desnormalización, distribución en ficheros³, reglas de negocio dentro de las bases de datos (EDVHV GH GDWRV DFWLYDV), aspectos de desarrollo relacionados con el WWW... Este apartado, debe convertirse en el resumen de la experiencia práctica del proyecto, y por sí mismo justifica que la memoria se convierta en un documento útil, fuente de referencia para los autores, los tutores y futuros alumnos.

6. Trabajos relacionados

Este apartado sería parecido a un estado del arte de una tesis o tesina. En un trabajo final grado no parece obligada su presencia, aunque se puede dejar a juicio del tutor el incluir un pequeño resumen comentado de los trabajos y proyectos ya realizados en el campo del proyecto en curso.

7. Conclusiones y Líneas de trabajo futuras

Todo proyecto debe incluir las conclusiones que se derivan de su desarrollo. Éstas pueden ser de diferente índole, dependiendo de la tipología del proyecto, pero normalmente van a estar presentes un conjunto de conclusiones relacionadas con los resultados del proyecto y un conjunto de conclusiones técnicas. Además, resulta muy útil realizar un informe crítico indicando cómo se puede mejorar el proyecto, o cómo se puede continuar trabajando en la línea del proyecto realizado.

Bibliografía

- [1] John Atkinson-Abutridy. *Analítica textual*. Marcombo.
- [2] Aishwarya Bhangale. Introduction to Topic Modelling with LDA, NMF, Top2Vec and BERTopic, 2023. <https://medium.com/blend360/introduction-to-topic-modelling-with-lda-nmf-top2vec-and-bertopic-ffc3624d44e4>, [Internet, descargado 10-noviembre-2025].
- [3] Iqra Bismi. Topic modelling using LDA, 2023. <https://medium.com/@iqra.bismi/topic-modelling-using-lda-fe81a2a806e0>, [Internet, descargado 10-noviembre-2025].
- [4] Gustavo Espíndola. ¿Qué son los embeddings y cómo se utilizan en la inteligencia artificial con python?, 2023. <https://gustavo-espindola.medium.com/qu%C3%A9-son-los-embeddings-y-c%C3%B3mo-se-utilizan-en-la-inteligencia-artificial-con-python-45b751ed86a5>.
- [5] Thiyaneshwaran G. Top2vec for Topic Modeling and Semantic Similarity and Search, 2022. <https://medium.com/@ThiyaneshwaranG/top2vec-for-topic-modeling-and-semantic-similarity-and-search-77db82dda7d3>.
- [6] Lin Gan, Tao Yang, Yifan Huang, Boxiong Yang, Yami Yanwen Luo, Lui Wing Cheung Richard, and Dabo Guo. Experimental comparison of three topic modeling methods with lda, top2vec and bertopic. In *International Symposium on Artificial Intelligence and Robotics*, pages 376–391. Springer, 2023.

- [7] Madhurima Nath. Topic modeling algorithms, 2023. <https://medium.com/@m.nath/topic-modeling-algorithms-b7f97cec6005>, [Internet; descargado 10-noviembre-2025].
- [8] Xiaobao Wu, Thong Nguyen, Delvin Ce Zhang, William Yang Wang, and Anh Tuan Luu. FASTopic: Pretrained Transformer is a Fast, Adaptive, Stable, and Transferable Topic Model. *arXiv e-prints*, 2024.