



UNIVERSIDAD DE BURGOS  
ESCUELA POLITÉCNICA SUPERIOR  
Grado en Ingeniería Informática



TFG del Grado en Ingeniería  
Informática

*TFG Topics*

Análisis de temas en Trabajos Fin de  
Grado



Presentado por Zeldan Javier Campos Cordero  
en Universidad de Burgos — 26 de mayo  
de 2026

Tutor: Carlos López Nozal







UNIVERSIDAD DE BURGOS  
ESCUELA POLITÉCNICA SUPERIOR  
Grado en Ingeniería Informática



D. Carlos López Nozal, profesor del departamento de Ingeniería Informática, área de Lenguajes y Sistemas Informáticos.

Expone:

Que el alumno D. Zeldan Javier Campos Cordero, con DNI 55462889E, ha realizado el Trabajo final de Grado en Ingeniería Informática titulado Análisis de temas en Trabajos Fin de Grado.

Y que dicho trabajo ha sido realizado por el alumno bajo la dirección del que suscribe, en virtud de lo cual se autoriza su presentación y defensa.

En Burgos, 26 de mayo de 2026

Vº. Bº. del Tutor:

D. Carlos López Nozal





## Resumen

*TFG Topics* es una aplicación orientada al análisis temático cualitativo de los textos asociados a los **Trabajo de Fin de Grado (TFG)**. El objetivo principal es facilitar a docentes, investigadores y estudiantes la exploración del contenido académico, la identificación de tendencias y la comparación de resultados entre cursos.

El sistema parte de un conjunto de datos construido a partir de repositorios públicos en GitHub, incluyendo contenido de memorias de **TFG** en formato  $\text{\LaTeX}$ , ficheros *readmes*, *issues* y abstracts. Sobre este corpus se aplica un flujo de preprocesamiento y modelado de temas mediante **Latent Dirichlet Allocation (LDA)** [28], **Top2Vec** [22], **BERTopic** [36] y **FASTopic** [45].

El trabajo se centra en el diseño e implementación de la solución, así como en la comparación de los modelos para valorar su utilidad en un contexto académico real. Como resultado, se obtiene una herramienta reproducible para apoyar la gestión del conocimiento y el análisis de la producción académica universitaria.

## Descriptores

Análisis temático, Topic Modeling, LDA, BERTopic, Top2Vec, FASTopic, TFG, Análisis de Datos, Procesamiento del Lenguaje Natural, Ingeniería Informática.

## Abstract

*TFG Topics* is an application for qualitative thematic analysis of texts related to Final Degree Projects. Its main goal is to support teachers, researchers, and students in exploring academic content, identifying trends, and comparing results across academic years.

The system uses a dataset built from public GitHub repositories, including L<sup>A</sup>T<sub>E</sub>X reports, readme files, issues, and academic abstracts. A full text processing and topic modeling pipeline is applied using **Latent Dirichlet Allocation (LDA)** [28], **Top2Vec** [22], **BERTopic** [36], and **FASTopic** [45].

This work focuses on the design and implementation of the solution, together with a comparative analysis of the selected models in a real academic setting. The final result is a reproducible tool that supports academic knowledge management and thematic exploration.

## Keywords

Topic Modeling, LDA, BERTopic, Top2Vec, FASTopic, TFG, Data Analysis, NLP, Computer Science.

---

# Índice general

---

|                                                     |            |
|-----------------------------------------------------|------------|
| <b>Índice general</b>                               | <b>iii</b> |
| <b>Índice de figuras</b>                            | <b>v</b>   |
| <b>Índice de tablas</b>                             | <b>vi</b>  |
| <b>1. Introducción</b>                              | <b>1</b>   |
| <b>2. Objetivos del proyecto</b>                    | <b>3</b>   |
| 2.1. Objetivo general . . . . .                     | 3          |
| 2.2. Objetivos específicos . . . . .                | 3          |
| 2.3. Objetivos personales . . . . .                 | 4          |
| <b>3. Conceptos teóricos</b>                        | <b>5</b>   |
| 3.1. Procesamiento de lenguaje natural . . . . .    | 5          |
| 3.2. Preprocesamiento del textos . . . . .          | 6          |
| 3.3. Representación del texto . . . . .             | 9          |
| 3.4. Modelado de temas . . . . .                    | 10         |
| 3.5. Evaluación de modelos . . . . .                | 14         |
| 3.6. Hiperparametrización de Modelos . . . . .      | 16         |
| 3.7. Comparación de modelos . . . . .               | 18         |
| <b>4. Técnicas y herramientas</b>                   | <b>21</b>  |
| 4.1. Metodologías de desarrollo . . . . .           | 22         |
| 4.2. Herramientas de gestión de proyectos . . . . . | 22         |
| 4.3. Herramientas de desarrollo . . . . .           | 22         |
| 4.4. Documentación . . . . .                        | 26         |

|                                                                          |           |
|--------------------------------------------------------------------------|-----------|
| <b>5. Aspectos relevantes del desarrollo del proyecto</b>                | <b>27</b> |
| 5.1. Arquitectura y diseño del software . . . . .                        | 27        |
| 5.2. Gestión de los datos y almacenamiento de resultados . . . . .       | 28        |
| 5.3. Optimización de hiperparámetros y gestión de experimentos . . . . . | 29        |
| 5.4. Despliegue y modos de ejecución . . . . .                           | 29        |
| 5.5. Interfaz web y exploración de resultados . . . . .                  | 30        |
| <b>6. Trabajos relacionados</b>                                          | <b>33</b> |
| <b>7. Conclusiones y Líneas de trabajo futuras</b>                       | <b>35</b> |
| 7.1. Líneas de trabajo futuras . . . . .                                 | 36        |
| <b>Acrónimos</b>                                                         | <b>39</b> |
| <b>Glosario</b>                                                          | <b>41</b> |
| <b>Bibliografía</b>                                                      | <b>45</b> |

---

## Índice de figuras

---

|                                                                           |    |
|---------------------------------------------------------------------------|----|
| 3.1. Pipeline general del preprocesamiento de lenguaje natural. . . .     | 6  |
| 4.1. Esquema de las principales tecnologías y librerías utilizadas. . .   | 21 |
| 5.1. Diagrama conceptual de los modos de ejecución del proyecto. . .      | 30 |
| 5.2. Vista general de la interfaz interactiva desarrollada con Streamlit. | 31 |

---

# Índice de tablas

---

|                                                                                            |    |
|--------------------------------------------------------------------------------------------|----|
| 1.1. Fuentes textuales incluidas en el alcance del proyecto . . . . .                      | 2  |
| 3.1. Comparativa de las características de los algoritmos de modelado<br>de temas. . . . . | 19 |
| 4.1. Flujo de desarrollo, control de versiones y validación continua. .                    | 25 |

---

# 1. Introducción

---

En el ámbito universitario se genera cada curso una gran cantidad de documentos académicos que proporcionan una valiosa fuente de información. Entre ellos, las memorias de los **Trabajo de Fin de Grado (TFG)** que ocupan un lugar relevante, ya que forman parte fundamental del proceso formativo del estudiante, y permiten aplicar los conocimientos adquiridos durante la realización de los estudios de grado [39]. Al recopilar las tecnologías empleadas, los enfoques metodológicos adoptados y las líneas de desarrollo abordadas, estos documentos conforman una fiel radiografía del conocimiento generado en las diversas ramas de la ingeniería informática. Sin embargo, el principal problema es que esta información suele estar dispersa en repositorios y formatos heterogéneos, lo que dificulta su consulta sistemática.

Este trabajo tiene como finalidad el desarrollo de una aplicación orientada al análisis cualitativo de los textos asociados a **TFG** del Grado en Ingeniería Informática de la Universidad de Burgos. Permitiendo explorar, comparar resultados, detectar tendencias temáticas y facilitar la consulta de contenido académico a lo largo del tiempo. Para ello, se parte de un conjunto de datos obtenido de repositorios públicos en GitHub, centrado en contenido de memorias de **TFG** en formato  $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ , ficheros *readmes*, *issues* y *abstracts*. Como se muestra en la Tabla 1.1.

Sobre este corpus se aplican técnicas de modelado de temas con distintos enfoques, entre ellos: **Latent Dirichlet Allocation (LDA)** [28], **Top2Vec** [32], **BERTopic** [36] y **FASTopic** [45]. El propósito no es únicamente obtener resultados automáticos, sino también comparar el comportamiento de los modelos y estudiar su utilidad en un contexto académico real.

La solución implementada se estructura en tres módulos: ingesta de datos, procesamiento/modelado y visualización. Esta separación permite desaco-

| Fuente textual      | Uso principal en el proyecto                                                                  |
|---------------------|-----------------------------------------------------------------------------------------------|
| <i>readmes</i>      | Descripción general del repositorio, tecnologías empleadas y contexto funcional del trabajo.  |
| <i>issues</i>       | Información complementaria sobre incidencias, decisiones técnicas y evolución del desarrollo. |
| <i>memorias TFG</i> | Contenido textual completo de las memorias en formato $\text{\LaTeX}$ .                       |
| <i>abstracts</i>    | Resúmenes académicos para análisis comparativo de temas de forma directa.                     |

Tabla 1.1: Fuentes textuales incluidas en el alcance del proyecto

plar responsabilidades, mejorar la mantenibilidad del sistema y facilitar su reproducibilidad en distintos entornos de ejecución.

Desde el punto de vista teórico, este proyecto se fundamenta en el uso de técnicas de modelado de temas, una tarea de aprendizaje no supervisado donde se identifica la estructura temática de un grupo de documentos [25]. Al utilizar estas técnicas es posible encontrar temas relevantes para organizar, buscar o comprender grandes cantidades de datos en formato de texto. Estos modelos se basan en el supuesto de que cada documento puede representarse como una combinación de temas, donde cada tema es una distribución de términos con distinta relevancia probabilística.

Esta memoria se estructura del siguiente modo: en **Objetivos del proyecto** se definen el objetivo general y los objetivos específicos; en **Conceptos teóricos** se presenta el marco conceptual del modelado de temas; en **Técnicas y herramientas** se describen las tecnologías utilizadas; en **Aspectos relevantes del desarrollo del proyecto** se detallan la metodología seguida, las decisiones técnicas y las dificultades abordadas; en **Trabajos relacionados** se analizan propuestas similares y se compara su enfoque con el de este trabajo; y, por último, en **Conclusiones y líneas de trabajo futuras**, se recogen los resultados obtenidos y las posibles extensiones del sistema.

---

## 2. Objetivos del proyecto

---

El presente Trabajo Fin de Grado tiene como objetivo principal el desarrollo de una aplicación capaz de realizar análisis temáticos cualitativos sobre los textos contenidos en las memorias de los Trabajo de Fin de Grado (TFG) en Ingeniería Informática. Las memorias, *issues*, *readmes*, *abstracts* y demás documentos descriptivos del TFG se encuentran disponibles en repositorios de software alojados en la plataforma GitHub.

Este proyecto busca aplicar técnicas de procesamiento del lenguaje natural y modelado de temas para facilitar el análisis, explorar y comparar resultados, detectar tendencias temáticas y facilitar la consulta de contenido académico a lo largo del tiempo.

### 2.1. Objetivo general

Diseñar e implementar una aplicación que permita realizar análisis temáticos automáticos sobre la documentación disponible en los repositorios del TFG, como *readmes*, *issues*, memorias en formato L<sup>A</sup>T<sub>E</sub>X y resúmenes académicos, utilizando para ello distintos algoritmos de modelado de temas y evaluando su rendimiento en términos de coherencia y calidad temática.

### 2.2. Objetivos específicos

Para alcanzar el objetivo general, se plantean los siguientes objetivos específicos:

- **Recopilar y preparar los datos:** Construir un conjunto de datos a partir de **TFG** disponibles públicamente en GitHub, integrando las fuentes *issues*, *readmes*, memorias y *abstracts*.
- **Implementar diferentes algoritmos de modelado de temas:** Aplicar y comparar métodos como **LDA**, **Top2Vec**, **BERTopic** y **FASTopic**.
- **Evaluar el rendimiento de los modelos:** Medir y comparar la calidad de los temas generados mediante métricas de coherencia.
- **Desarrollar una interfaz visual:** Diseñar una aplicación que permita la exploración interactiva de resultados por modelo, dataset y métricas.
- **Fomentar la gestión del conocimiento académico:** Facilitar el acceso y la reutilización del conocimiento generado por estudiantes en cursos anteriores, como apoyo a docencia e investigación.
- **Diseño de arquitectura:** Diseñar e implementar una arquitectura de software modular que separe ingesta, procesamiento y visualización, siguiendo principios de Ingeniería del Software.
- **Gestión:** Aplicar herramientas y metodologías ágiles para planificar y hacer seguimiento del proyecto, utilizando GitHub y Zube.

## 2.3. Objetivos personales

- Crear una herramienta que sea de utilidad para la comunidad universitaria.
- Aplicar conocimientos adquiridos durante el grado, especialmente en el ámbito de Desarrollo Avanzado de Sistemas Software y Minería de Datos.
- Consolidar conocimientos en las siguientes tecnologías: Python, Git y Docker.
- Mejorar habilidades de diseño de software, aplicación de buenas prácticas en desarrollo, testing de software y documentación.

---

## 3. Conceptos teóricos

---

A continuación se exponen conceptos teóricos que sientan las bases del proyecto, cubriendo desde el pre-procesamiento de texto hasta los algoritmos avanzados de modelado.

### 3.1. Procesamiento de lenguaje natural

El procesamiento de lenguaje natural (**NLP**, del inglés **Natural Language Processing**) es un campo de la Inteligencia Artificial (**AI**, del inglés **Artificial Intelligence**) que se ocupa del análisis y la interpretación de textos que se encuentran en lenguaje humano. Utilizando estas técnicas los computadores pueden dar sentido a los datos contenidos en un conjunto de textos y así adquirir su conocimiento implícito [24].

**NLP** usa gran variedad de técnicas y modelos para analizar diferentes aspectos de los textos como la formación de palabras, el léxico, la sintaxis entre otros, con esto se pretende resolver problemas específicos relacionados con el lenguaje.

Entre las técnicas más usadas en **NLP** se encuentran la **Tokenización**, **Lematización**, eliminación de palabras vacías (del inglés **Stopwords**), análisis sintáctico y extracción de información. En el contexto de este trabajo, las técnicas de **NLP** se utilizan para preparar los textos de las memorias de **TFG**, transformándolos en datos estructurados que puedan ser analizados mediante algoritmos de modelado de temas.

## 3.2. Preprocesamiento del textos

Antes de iniciar cualquier análisis los textos deben someterse a una serie de procesos secuenciales para garantizar su limpieza, normalización y reducir la dimensión del vocabulario, con el fin de garantizar la calidad de los análisis resultantes. El flujo general de estas transformaciones se ilustra en la Figura 3.1.




Figura 3.1: Pipeline general del preprocesamiento de lenguaje natural.

### Tokenización

La **Tokenización** es un proceso fundamental dentro de el **NLP** y la **AI**, pues permite dividir el texto en unidades mínimas denominadas tokens, que pueden ser palabras, subpalabras, caracteres o unidades semánticas mas complejas [38]. Este proceso constituye la base para la mayoría de técnicas posteriores de análisis textual, ya que permite transformar cadenas de texto sin estructura en secuencias manejables por algoritmos computacionales.

La **Tokenización** presenta una serie de problemas que son específicos de cada idioma. Por lo tanto, se requiere conocer el idioma del documento. La identificación del idioma mediante clasificadores que usan subsecuencias

cortas de caracteres como características resulta muy efectiva, ya que la mayoría de los idiomas tienen patrones distintivos [11].

## Tipos de Tokenización

Existen varios métodos comunes para realizar esta segmentación

**Tokenización de palabras** El texto se divide en palabras individuales basándose en un delimitador, típicamente el espacio. Esta representación puede fallar con palabras compuestas o en idiomas sin espacios entre palabras (como el chino) [34].

**Tokenización de caracteres** El texto se divide en caracteres individuales. Este método es útil para lenguajes con alfabetos complejos y permite al modelo manejar un rango más amplio de entradas, como palabras desconocidas o errores tipográficos [29, 34].

**Tokenización de subpalabras** El texto se divide en subpalabras o fragmentos frecuentes de caracteres. Este método reduce la dimensionalidad y maneja eficazmente palabras raras y desconocidas [29, 34].

**Tokenización de espaciado blanco** Divide el texto basándose únicamente en los espacios, lo que resulta en una gestión incorrecta de puntuaciones o errores gramaticales [29].

En el contexto del análisis temático de TFG, la Tokenización cumple varias funciones clave:

- Estandarizar los textos, permitiendo compararlos entre sí.
- Reduce ruido, al separar puntuación, símbolos o caracteres no relevantes.
- Facilita operaciones posteriores, como Lematización, extracción de n-grams o cálculo de frecuencias.
- Mejora la precisión del modelado de temas, ya que una buena segmentación permite que los modelos identifiquen patrones semánticos coherentes.

En particular para este trabajo la Tokenización presenta varios problemas o desafíos:

**Tratamiento de compuestos** palabras como “aprendizaje-servicio” deben decidirse como uno o dos tokens.

**Abreviaturas universitarias** “TFG”, “EPS”, “ECTS”, etc., que pueden requerir reglas específicas.

**Símbolos técnicos o matemáticos** comunes en textos de informática.

**Preservación del contexto** eliminar puntuación puede afectar el significado y pérdida de contexto en algunos casos.

La **Tokenización** es un proceso esencial y su correcta implementación afecta directamente la calidad del análisis temático y de los modelos posteriores, desde la extracción de palabras clave hasta el modelado de temas.

## Lematización

La **Lematización** es una técnica clave dentro del **NLP** que tiene como principal objetivo transformar o reducir las palabras a su forma canónica o lema, es decir, la forma bajo la cual se encontrarían en un diccionario. En muchas lenguas, el infinitivo se utiliza como lema para el verbo; por ejemplo, en español, dormir es el lema para la forma duermes [38].

El lema (*lemma*) se define como la forma de citación o forma base de una palabra. El concepto del lema es relevante para comprender la estructura del significado. Un lema puede ser polisémico, es decir, puede tener múltiples sentidos. Cada aspecto individual del significado de un lema se denomina sentido de palabra (*word sense*). Por ejemplo, el lema ratón tiene al menos dos sentidos distintos: El roedor o el dispositivo de control de cursor [38].

La **Lematización**, al reducir las palabras a su forma base, asegura que un sistema de **NLP** trate variantes flexionales (como singular, plural o diferentes tiempos verbales) como la misma unidad, facilitando la generalización sobre el significado fundamental de la palabra.

## Stopwords

Las palabras vacías (del inglés **Stopwords**) es un término que hace referencia a las palabras que deben ser eliminadas en la fase de **Preprocesamiento de texto** para garantizar la precisión y eficiencia de las tareas de **NLP**. Estas palabras aparecen frecuentemente en muchos documentos, pero transmiten poca o nula información sobre la sección del texto al que pertenecen [42].

Al eliminar estas palabras que aportan baja información, se incrementa la significación estadística de los términos que si son relevantes y son verdaderamente importantes para la tarea. Ejemplos específicos de estas palabras son: cada, sobre, tal, el, la, entre otros [42].

Históricamente, se han realizado esfuerzos para identificar **Stopwords** a partir de fuentes de conocimiento genéricas, como *Brown Corpus* o *20 newsgroup corpus*. Esto ha provocado la creación de listas genéricas que se utilizan en aplicaciones de **NLP**. Una de las listas más utilizadas es la distribuida con el paquete de Python **NLTK** (del inglés, **Natural Language Tool Kit**) [42].

Sin embargo, el lenguaje técnico utilizado en textos de ingeniería o tecnología se distingue del lenguaje común. El lenguaje técnico contiene su propio argot y palabras altamente frecuentes y poco informativas que no están presentes en las listas genéricas. No existe una lista estándar de **Stopwords** para aplicaciones de procesamiento de lenguaje técnico. La adopción simple de listas genéricas deja muchos términos repetitivos y poco informativos específicos del dominio en los datos. Es por esto que el proceso de identificación de **Stopwords** incluye una etapa posterior de evaluación humana por parte de expertos para confirmar que el término no contiene información sobre ingeniería y tecnología [42].

### 3.3. Representación del texto

#### Bolsa de palabras

La bolsa de palabras (**BOW**, inglés **Bag of Words**) es una de las técnicas de representación de texto utilizada por distintas aplicaciones de **NLP**. Esta representación se basa en el conteo de palabras, ignorando el orden y la estructura gramatical del texto [37].

El método **BOW** implica la construcción de un vocabulario compuesto por todas las palabras únicas presentes en los documentos analizados y la definición de una métrica concreta para determinar el peso de cada termino. Las métricas más empleadas para este fin son la frecuencia de términos (**TF**, inglés **Term Frequency**), y la frecuencia inversa de documentos (**TF-IDF**, del inglés **Term Frequency-Inverse Document Frequency**) [37].

Una de las principales limitaciones de **BOW** es la pérdida de información contextual de los términos dentro de los documentos. Otro inconveniente de **BOW** es que no captura el significado de las palabras y trata todas las

palabras como entidades independientes dentro del documento. Además, la vectorización mediante **BOW** genera vectores dispersos de alta dimensión cuando se trabaja con **Corpus** extensos, lo que incrementa la complejidad computacional y los requisitos de memoria. **BOW** no es capaz de gestionar los sinónimos, tratando palabras con un mismo significado como si estuvieran relacionadas [37].

## Representaciones vectoriales

Debido a las limitaciones encontrados en otras formas de representación de texto como **BOW**, han surgido técnicas que buscan solucionar estos problemas, entre las cuales podemos encontrar a los **Embeddings**. Los **Embeddings** son una técnica de procesamiento de lenguaje natural que convierte el lenguaje humano en vectores matemáticos. Estos vectores son una representación del significado subyacente de las palabras, lo que permite que las computadoras procesen el lenguaje de manera más efectiva [30].

Los **Embeddings** intentan solucionar el problema de la pérdida de contexto y semántica de **BOW** considerando el orden y la secuencia de aparición de cada término. Estos modelos se construyen sobre redes neuronales artificiales (**ANN**, inglés **Artificial Neural Networks**) y se entrenan con grandes cantidades de datos para capturar el significado contextual de una unidad léxica en función de las palabras que la rodean, y viceversa. Cada palabra en el espacio de **Embeddings** se representa como un vector de números reales con una dimensión predefinida. En un espacio de vectores de palabras, es posible identificar las palabras más similares a un término concreto del vocabulario utilizando métodos como la **Similitud del coseno** o la **Distancia euclidiana**. Estas técnicas permiten agrupar palabras relacionadas, clasificar textos, categorizar documentos y descubrir temas o temas latentes dentro del texto [37].

### 3.4. Modelado de temas

El **Modelado de temas** (del inglés *Topic Modeling*) es una técnica muy utilizada con la cual podemos encontrar temas subyacentes dentro de un grupo de documentos que deseamos analizar. Esta sigue un enfoque estadístico y proporciona una forma de representar textos de una manera estructurada, lo que la hace ideal para analizar grandes conjuntos de datos textuales [27].

Dependiendo del algoritmo utilizado los términos se pueden obtener utilizando distintos enfoques como la bolsa de palabras **BOW**, frecuencia de términos, frecuencia inversa de términos o basado en clases [40].

Podemos destacar la importancia del modelado de temas en los siguientes aspectos [27]:

**Organización de la información** permite categorizar los documentos en temas lo cual hace más fácil el proceso de búsqueda.

**Resumen** permite capturar la esencia de la temática del documento.

**Recomendación** facilita realizar recomendaciones personalizadas para cada usuario usuarios

En este **TFG** nos centraremos en el uso de los siguiente modelos:

**LATENT DIRICHLET ALLOCATION (LDA)** Es un modelo probabilístico clásico que data de 2003. Se basa en el enfoque de bolsa de palabras (**BOW**) y asume que los documentos son una mezcla de temas y los temas una mezcla de palabras. Este es una referencia fundamental en el modelado de temas [28]. En la sección 3.4 se profundiza sobre este modelo.

**Top2Vec** Surge en 2020 como una alternativa que utiliza **Embeddings** de palabras y documentos para encontrar temas. Este crea un espacio semántico unificado donde los vectores de temas, documentos y palabras coexisten, permitiendo una búsqueda semántica y la detección automática del número de temas [22]. En la sección 3.4 se profundiza sobre este modelo.

**BERTopic** También de 2020, este modelo aprovecha el poder de los **Embeddings** contextuales de los transformadores (como **BERT**). Su arquitectura modular combina la **Reducción de dimensionalidad** con **UMAP** y el **Clustering** con **HDBSCAN** para identificar temas semánticamente coherentes, ofreciendo una gran flexibilidad [36]. En la sección 3.4 se profundiza sobre este modelo.

**FASTopic** Es el modelo más reciente, de 2023, y se presenta como una evolución de los modelos basados en **Embeddings**. Introduce un enfoque optimizado para ser más rápido, estable y escalable, manteniendo la alta calidad de los temas. Está diseñado para funcionar eficientemente en grandes volúmenes de datos [45]. En la sección 3.4 se profundiza sobre este modelo..

## Latent Dirichlet Allocation (LDA)

**Latent Dirichlet Allocation (LDA)** es un modelo probabilístico que usa matrices de factorización basado en la distribución de Dirichlet. En este modelo se asume que cada documento expone una serie de temas y cada tema se caracteriza por una distribución de palabras basada en la frecuencia de aparición en el documento. Los resultados obtenidos al ejecutar el modelo no son deterministas, por lo que se puede obtener un resultado distinto en cada ejecución para el mismo *dataset* [40, 27].

**LDA** posee dos parámetros [26] que debemos ajustar para mejorar los resultados obtenidos:

- Numero de temas
- Factor de densidad del documento-tema
- Factor de densidad tema-palabra

## Top2Vec

Top2Vec es un algoritmo de modelado de temas basado en **Embeddings**, documentos y vectores de palabras. Este algoritmo asume que la semántica interna de los documentos es indicativo de que existe una temática común [32].

A diferencia de otros métodos como **LDA**, Top2Vec genera simultáneamente **Embeddings** de documentos, **Embeddings** de palabras y **Embeddings** de temas, lo que le permite identificar agrupaciones semánticas de forma más natural y continua. Este enfoque se basa en la idea de que los documentos que tratan temas similares deben estar próximos entre sí en un espacio vectorial de alta dimensión. Mediante el uso de modelos de lenguaje basados en redes neuronales, Top2Vec representa documentos y palabras en un espacio semántico compartido, permitiendo descubrir temas como densidades locales o agrupaciones (del inglés *clusters*) de documentos [22].

Ventajas de Top2Vec [22]:

- No requiere preprocesamiento, ya que funciona bien sin necesidad de: eliminación de **Stopwords**, realizar **Lematización**, limpiar puntuación, filtrar términos raros, etc.
- No requiere elegir el número de temas.

- Produce temas con alta **Coherencia** semántica.
- Permite buscar documentos por similitud, identificar documentos mas representativos de un tema.

## BERTopic

BERTopic es un método de modelado de temas que combina **Embeddings** semánticos, **Reducción de dimensionalidad** y **Clustering** para identificar temas en grandes colecciones de texto de manera automática y precisa [36]

BERTopic se basa en el uso de **Bidirectional Encoder Representations from Transformers (BERT)** para generar representaciones vectoriales **Embeddings** de los documentos y temas. El proceso se ejecuta fundamentalmente en dos fases: la codificación semántica y la extracción de temas. En la primera fase, los documentos se transforman en **Embeddings** de alta dimensionalidad mediante **BERT**. Posteriormente, se emplea el algoritmo **HDBSCAN** para agrupar estos vectores y así identificar clústeres en el espacio vectorial, permitiendo la clasificación de los textos en distintos temas. A partir de cada grupo, se derivan las palabras clave que describen el contenido [33].

BERTopic combina cuatro componentes principales:

- **Embeddings** (representaciones semánticas)
- **Reducción de dimensionalidad (UMAP)**, una técnica que reduce las dimensiones de los **Embeddings** manteniendo las relaciones importantes.
- **Clustering** basado en densidad (**HDBSCAN**), es un algoritmo que detecta “grupos naturales” en los datos.
- Representación final de temas (**c-TF-IDF**), método para identificar las palabras más representativas de cada tema.

La principal ventaja de BERTopic es su capacidad para encontrar matices semánticos y manejar grandes volúmenes de información textual. Puede identificar significados complejos y relaciones contextuales con mayor precisión. Además, a diferencia de otros métodos, no es necesario fijar de antemano cuántos temas se generarán, ya que el algoritmo de **Clustering** determina este número automáticamente [33].

## FASTopic

FASTopic (*Fast, Adaptive, Stable and Transferable topic model*). Es un modelo que sigue el enfoque denominado **Reconstrucción de Relaciones Semánticas Dual (DSR)**, este no utiliza redes neuronales y se basa en tres elementos: la representación vectorial de los documentos generados por un transformador predeterminado, los vectores de temas y de palabras [45].

**DSR** captura dos tipos de relaciones semánticas: entre documentos y temas, y entre temas y palabras, interpretándolas como distribuciones que permiten descubrir los temas de manera ordenada y eficiente, eliminando la necesidad de estructuras complicadas. Para modelar estas relaciones, se propone además el **Embedding Transport Plan (ETP)**, un mecanismo novedoso que, en lugar de emplear funciones *softmax* parametrizadas, regula estas relaciones como planes de transporte óptimo entre los **Embeddings** de documentos, temas y palabras. Esto reduce el sesgo en las relaciones y permite obtener temas bien diferenciados y distribuciones más precisas [45].

FASTopic se basa en los siguientes pasos:

- Generación de **Embeddings** (representaciones semánticas).
- **Reducción de dimensionalidad**.
- **Clustering**, no se limitan a **HDBSCAN**, sino que permiten el uso de múltiples algoritmos de **Clustering** que buscan eficiencia y escalabilidad.
- Extracción de palabras representativas del tema.

FASTopic tiene como principales ventajas la capacidad de manejar documentos de gran tamaño si necesidad de utilizar mayor capacidad de procesamiento, no requiere limpieza extrema del texto y produce una calidad semántica similar a la de BERTopic cuando se usan buenos **Embeddings**.

## 3.5. Evaluación de modelos

Evaluar la calidad del resultado de los modelos es una parte esencial del proceso de análisis. Es importante verificar si los temas generados son coherentes, útiles y representativos para los textos.

La evaluación puede realizarse utilizando alguna de las siguientes técnicas:

- Utilizando métricas automáticas, que proporcionan valores numéricos objetivos.
- Evaluación humana o cualitativa, que revisa si los temas tienen sentido.
- Utilizando métricas híbridas, que combinan ambas aproximaciones.

## Métricas automáticas

Las métricas permiten comparar el resultado de los modelos sin necesidad de intervención humana, las más comunes son: perplexidad y coherencia.

### Perplejidad

Es una medida utilizada en modelos probabilísticos como **LDA**. Indica que tan bien el modelo es capaz de predecir documentos no vistos. Cuanto mas baja mejor se considera el desempeño del modelo, implica que el modelo tiene una mayor capacidad para anticipar las palabras de textos que no han sido utilizados durante el entrenamiento.

Solo es útil para comparar versiones diferentes del mismo tipo de modelo probabilístico (**LDA**). No es adecuada para modelos basados en **Embeddings** (BERTopic, Top2Vec, FASTopic).

### Coherencia

Es una métrica que evalúa que tan relacionados están los términos de las palabras más representativas de un tema. Esta métrica permite identificar cuantos temas son adecuados para un conjunto de datos determinado [41].

La **Coherencia** busca medir hasta qué punto las palabras más representativas de un tema tienden a aparecer juntas en el **Corpus** y a mantener relaciones semánticas coherentes. Una mayor **Coherencia** indica un tema más interpretable y semánticamente consistente.

Los métodos más usados son:

- **C\_V**: basada en similitud semántica.
- **UCI**: mide coocurrencias de palabras en **Ventana deslizante**.
- **UMass**: calcula coocurrencias dentro del propio **Corpus**.

Esta métrica funciona bien tanto en **LDA** como en BERTopic, Top2Vec o FASTopic.

## Evaluación Humana

El investigador revisa la lista de términos que componen cada tema y determina si son coherentes. En investigación cualitativa es habitual que varias personas evalúen los `phdTopicModelingAlgorithms2023` y se calcule el índice de acuerdo inter-evaluador. Esto ayuda a evitar que la evaluación dependa de la subjetividad de una sola persona [44]

## 3.6. Hiperparametrización de Modelos

Los hiperparámetros son valores configurados por el investigador antes de entrenar un modelo. Determinan el comportamiento del algoritmo, la calidad de los temas obtenidos y el tiempo de cómputo. Ajustarlos adecuadamente es esencial para obtener resultados óptimos en el análisis temático [28, 35].

### Hiperparámetros en LDA

**LDA** es uno de los modelos más sensibles a su configuración.

#### Número de temas ( $k$ )

Controla cuántos temas debe encontrar el modelo. Valores demasiado bajos generan temas demasiado generales, mientras que valores demasiado altos producen temas ruidosos o redundantes.

#### Parámetro $\alpha$

Regula cuántos temas aparecen en cada documento. Valores altos implican documentos con muchos temas mezclados; valores bajos generan documentos dominados por pocos temas.

#### Parámetro $\beta$

Determina cuántas palabras componen cada tema. Un valor alto genera temas más dispersos y un valor bajo produce temas más específicos.

#### Número de Iteraciones

Afecta la estabilidad del modelo. Más iteraciones proporcionan mejor convergencia a costa de un mayor tiempo de entrenamiento.

## Hiperparámetros en BERTopic

BERTopic tiene hiperparámetros en varias etapas: **Embeddings**, **Reducción de dimensionalidad** (**UMAP**), **Clustering** (**HDBSCAN**) y extracción de palabras mediante **c-TF-IDF**.

### UMAP

Los hiperparámetros más relevantes son:

- **n\_neighbors**: controla la influencia del vecindario local. Valores bajos encuentran temas más específicos.
- **n\_components**: número de dimensiones finales.

### HDBSCAN

Los ajustes más influyentes son:

- **min\_cluster\_size**: tamaño mínimo del grupo.
- **min\_samples**: sensibilidad al ruido.

## Hiperparámetros en Top2Vec

Top2Vec utiliza hiperparámetros principalmente en el modelo de **Embeddings** (**Doc2Vec**, **BERT** o USE) y en configuraciones de **UMAP** y **HDBSCAN** compartiendo muchos de los ajustes de BERTopic.

## Hiperparámetros en FASTopic

FASTopic está optimizado para grandes volúmenes de datos y permite configurar:

- tipo de embeddings (**BERT**, **FastText**, etc.).
- número de clusters en métodos rápidos como **K-Means**.
- número de palabras clave extraídas por tema.

Tanto la evaluación como la **Hiperparametrización** de modelos de temas son procesos fundamentales para garantizar la calidad del análisis temático. Modelos como LDA requieren ajustes cuidadosos en parámetros

probabilísticos, mientras que modelos modernos como BERTopic, Top2Vec y FASTopic dependen más de configuraciones de **Embeddings**, **Reducción de dimensionalidad** y **Clustering**. La combinación de métricas automáticas y evaluación humana proporciona la estrategia más robusta para obtener temas coherentes y útiles en contextos como el análisis de **TFG**.

## Métodos de búsqueda de hiperparámetros

Existen diversas estrategias para ajustar hiperparámetros, con distintos niveles de complejidad y eficiencia:

- **Grid Search**: explora todas las combinaciones posibles dentro de un conjunto definido. Sin embargo, resulta poco eficiente cuando el número de hiperparámetros es elevado [31].
- **Random Search**: selecciona combinaciones aleatorias de hiperparámetros dentro de los rangos definidos. Ha demostrado ser más eficiente que la búsqueda exhaustiva en espacios de gran dimensionalidad [31].
- **Optimización Bayesiana**: construye un modelo probabilístico del rendimiento y selecciona nuevas combinaciones basadas en regiones prometedoras del espacio de búsqueda. Es una opción muy eficiente cuando las evaluaciones del modelo son costosas [43].

### 3.7. Comparación de modelos

Con el objetivo de visualizar las diferencias de los distintos modelos seleccionados, en la Tabla ?? se presentan las propiedades de los cuatro algoritmos de modelado de temas evaluados. Esta comparación permite visualizar la evolución desde los modelos probabilísticos clásicos hacia los más recientes.

| Características                      | LDA   | Top2Vec                      | BERTopic                       | FASTopic                       |
|--------------------------------------|-------|------------------------------|--------------------------------|--------------------------------|
| Requiere indicar número de temas $k$ | Sí    | No                           | No                             | No                             |
| Uso de <i>embeddings</i>             | No    | Sí                           | Sí                             | Sí                             |
| Representación del texto             | BOW   | <i>embeddings</i> semánticos | <i>embeddings</i> contextuales | <i>embeddings</i> contextuales |
| Preprocesamiento necesario           | Alto  | Muy bajo                     | Moderado                       | Bajo                           |
| Coherencia de temas                  | Media | Muy Alta                     | Alta                           | Muy Alta                       |
| Coste computacional                  | Bajo  | Alto                         | Alto                           | Alto                           |
| Interpretabilidad                    | Alta  | Media                        | Media-Alta                     | Media                          |

Tabla 3.1: Comparativa de las características de los algoritmos de modelado de temas.



---

## 4. Técnicas y herramientas

---

En este capítulo se describen las técnicas y herramientas utilizadas durante el desarrollo del proyecto. Se abordan tanto las metodologías empleadas como las herramientas de software que facilitaron la implementación y gestión del mismo.

En la Figura 4.1 se presenta un resumen conceptual del ecosistema tecnológico empleado, categorizado por su función principal dentro de la arquitectura.



Figura 4.1: Esquema de las principales tecnologías y librerías utilizadas.

## 4.1. Metodologías de desarrollo

El desarrollo del proyecto se llevó a cabo utilizando la metodología ágil **Scrum Framework (SCRUM)** [21] de forma adaptada al contexto de un proyecto académico individual. Esta metodología permitió una gestión flexible y adaptativa del proyecto. El trabajo se organizó en **Sprint** de dos semanas, donde se definieron objetivos claros y se realizaron revisiones periódicas para evaluar el progreso. Frente a metodologías estrictamente secuenciales, este enfoque resulta especialmente adecuado en proyectos de carácter experimental, como es el caso del modelado de temas, donde los resultados dependen en gran medida de la calidad del preprocesado y de la configuración de los modelos.

Para la planificación de tareas y realizar seguimiento del proyecto se utilizó la aplicación web **Zube** [47]. Esta herramienta se integra **Kanban**.

Para seguir el flujo de trabajo de **SCRUM** y facilitar el proceso de desarrollo, en este caso el tutor adoptó los roles de product owner y **SCRUM** master.

## 4.2. Herramientas de gestión de proyectos

Para la gestión del proyecto se utilizó la plataforma **GitHub**. Esta herramienta permitió el alojamiento y gestión del código fuente, permitiendo llevar un **Control de versiones** eficiente utilizando Git [3].

## 4.3. Herramientas de desarrollo

### Entorno de desarrollo

El entorno de desarrollo utilizado fue **Visual Studio Code**, un editor de código fuente ligero y gratuito desarrollado por Microsoft [12]. Este entorno ofrece una amplia gama de extensiones y funcionalidades que facilitan la escritura, depuración y gestión de código en múltiples lenguajes de programación. Fue una herramienta esencial para el desarrollo de este proyecto gracias a su amplia integración con *plugins* que ayudan al desarrollo y depuración con el lenguaje de programación Python. Además, Visual Studio Code cuenta con integración nativa con GitHub, lo que facilita la gestión de versiones. Se valoró el uso de otros entornos como **PyCharm** [19], pero se optó por Visual Studio por su ligereza y flexibilidad.

También se utilizó **Jupyter Notebooks** [9] para la experimentación y análisis de datos, ya que permite combinar código, visualizaciones y documentación en un solo documento interactivo.

## Lenguajes de programación

El lenguaje de programación principal utilizado en el desarrollo del proyecto fue **Python** [10]. Python es un lenguaje de alto nivel, interpretado y de propósito general, conocido por su sintaxis clara. Su elección se basa en la amplia gama de bibliotecas y **Framework** para el procesamiento de datos y modelado de temas disponibles.

### Bibliotecas y frameworks

El núcleo del proyecto se apoya en técnicas de **NLP** aplicadas al análisis de documentos. Para el procesamiento de datos y modelado de temas se utilizaron diversas bibliotecas de Python, entre las que destacan:

- **Pandas** [16]: Biblioteca fundamental para la manipulación y análisis de datos.
- **NumPy** [7]: Biblioteca para computación científica y manejo de arreglos multidimensionales.
- **Gensim** [2]: Biblioteca especializada en modelado de temas y procesamiento de lenguaje natural.
- **NLTK** [6]: Biblioteca para el procesamiento de lenguaje natural, usado para tareas básicas tokenización y *stopwords*.
- **spaCy** [14]: Biblioteca avanzada para procesamiento más avanzado de lenguaje natural.

Sobre los textos preprocesados se aplican técnicas de modelado de temas. Se han estudiado y utilizado distintos enfoques, desde modelos probabilísticos clásicos hasta métodos más recientes basados en representaciones vectoriales. La comparación entre estas técnicas permite analizar sus fortalezas y limitaciones en función de criterios como la coherencia semántica de los temas, la interpretabilidad y el coste computacional.

Se utilizaron las siguientes bibliotecas de Python para el modelado de temas:

- **LDA** [5]: Implementación del modelo Latent Dirichlet Allocation para descubrir temas en grandes colecciones de documentos.
- **BERTopic** [13]: Biblioteca que utiliza modelos de lenguaje basados en transformadores para generar representaciones de documentos y realizar clustering.
- **Top2Vec** [23]: Biblioteca que combina incrustaciones de documentos y clustering para identificar temas en grandes conjuntos de datos.
- **FASTopic** [1]: Biblioteca que utiliza técnicas de reducción de dimensionalidad y clustering para el modelado eficiente de temas en grandes conjuntos de datos.

En cuanto a la experimentación con modelos y la optimización de hiperparámetros, se ha utilizado **Optuna** [8] como herramienta principal para la exploración del espacio de configuraciones. Esta biblioteca permite definir procesos de búsqueda automatizados y eficientes y facilita la comparación objetiva de los resultados mediante métricas cuantitativas como la coherencia de los temas. Frente a la selección manual de parámetros, este enfoque resulta más riguroso y contribuye a la reproducibilidad y trazabilidad de los experimentos realizados.

Finalmente, para la presentación y exploración de los resultados se ha desarrollado una interfaz web utilizando la librería **Streamlit** [15]. Su elección se debe principalmente a que esta herramienta permite construir interfaces web interactivas de forma ágil sin entrar en detalles complejos de desarrollo web. Streamlit facilita la creación de paneles donde se pueden cargar datos y ajustar parámetros facilitando la visualización de los modelos generados y de sus métricas asociadas.

## Otras herramientas

Además de las herramientas mencionadas anteriormente, se utilizaron diversas herramientas de apoyo orientadas a la gestión del entorno de ejecución y a la calidad del software desarrollado.

En primer lugar, se ha utilizado **Docker** [17] y **Docker Compose** como tecnología de **Contenedorización**. Docker permite encapsular la aplicación junto con todas sus dependencias en entornos reproducibles y aislados, lo que simplifica tanto el despliegue como la ejecución del sistema en diferentes máquinas. Este enfoque resulta especialmente útil ya que reduce problemas

| Etapa                       | Acciones principales                                                          | Herramientas                                  |
|-----------------------------|-------------------------------------------------------------------------------|-----------------------------------------------|
| Planificación y seguimiento | Definición de tareas, priorización y revisión periódica del avance.           | Zube, GitHub Issues.                          |
| Implementación              | Desarrollo incremental por módulos y ejecución local o contenedorizada.       | Python, Visual Studio Code, Docker, Makefile. |
| Control de versiones        | Versionado del código, integración de cambios y trazabilidad de decisiones.   | Git, GitHub.                                  |
| Calidad estática            | Formateo, orden de importaciones, análisis de estilo y verificación de tipos. | Black, isort, flake8, mypy, pre-commit.       |
| Pruebas                     | Ejecución de pruebas unitarias por módulo y validación funcional de cambios.  | Pytest.                                       |
| Integración y despliegue    | Ejecución reproducible del Pipeline completo en distintos modos.              | Docker Compose, GHCR, Makefile.               |
| Documentación               | Redacción de memoria técnica y mantenimiento de documentación del proyecto.   | LaTeX, Visual Studio Code.                    |

Tabla 4.1: Flujo de desarrollo, control de versiones y validación continua.

derivados de incompatibilidades de versiones y facilita la portabilidad y reproducibilidad de los experimentos.

Por otro lado, se han utilizado sistemas orientados a garantizar la calidad del código. En primer lugar, para el formateo automático del código se ha utilizado **Black**, lo que asegura un estilo de código uniforme en todo el proyecto. La organización y limpieza de importaciones se ha gestionado usando **isort**, mientras que el análisis estático y la detección de posibles errores o incumplimientos de estilo se han realizado con **flake8**. Estas herramientas mejoran la legibilidad del código y reducen la aparición de errores durante el desarrollo. A modo de síntesis, en la Tabla 4.1 se detalla el flujo integral de desarrollo, control de versiones y validación continua aplicado.

## 4.4. Documentación

Para la creación de la documentación del proyecto se utilizó **LaTeX** [4]. LaTeX es especialmente adecuado para la creación de documentos técnicos y científicos debido a su capacidad para manejar fórmulas matemáticas complejas, referencias bibliográficas y estructuras avanzadas de documentos. Además, LaTeX permite separar el contenido de la presentación, facilitando la gestión y el formato del documento final. Se optó por LaTeX frente a procesadores de texto tradicionales como Microsoft Word o Google Docs, ya que estos últimos pueden presentar limitaciones en la gestión de referencias y fórmulas complejas. Además, la universidad proporciona plantillas pre formateadas y estandarizadas para la creación de la memoria en LaTeX. Como editor de LaTeX se utilizó Visual Studio Code con la extensión **LaTeX Workshop** [46].

---

## 5. Aspectos relevantes del desarrollo del proyecto

---

En este capítulo se describen los aspectos más relevantes y representativos del desarrollo del proyecto, poniendo el foco en las decisiones técnicas y de diseño adoptadas a lo largo de su ciclo de vida.

### 5.1. Arquitectura y diseño del software

Durante la fase de análisis y diseño del proyecto se tomaron decisiones clave. Debido a la naturaleza de los datos de entrada, documentos y textos que se obtienen de Github, provenientes de *issues*, *readmes*, y documentos en LaTeX de los distintos **TFG**, se decidió implementar un proceso específico de limpieza y normalización del texto, desacoplado del resto del sistema para facilitar su reutilización y evolución. También debido a la necesidad de experimentar con distintos enfoques de modelado de temas, se optó por diseñar una interfaz que permitiera la abstracción y así integrar diferentes proveedores de modelos. Estas necesidades influyeron directamente en el diseño del sistema, requiriendo una arquitectura flexible que permitiera integrar múltiples modelos sin modificar la lógica principal de la aplicación.

Durante la fase de análisis se identificaron claramente tres responsabilidades principales, que dieron lugar a la división del sistema en módulos independientes:

- Un módulo de **ingestión** (*backend-ingestion*), responsable de la obtención y persistencia de datos desde GitHub.

- Un módulo de **procesamiento** (*backend-processing*), encargado del preprocesado del texto, modelado de temas y evaluación.
- Un módulo de **visualización** (*frontend-web*), orientado a la exploración y análisis de los resultados generados.

Esta división facilitó el desarrollo incremental y permitió evolucionar cada módulo con un acoplamiento mínimo. En los módulos de *backend* se aplicó una arquitectura hexagonal [18], separando lógica de dominio, CUs y adaptadores de infraestructura. En la práctica, este enfoque mejoró la testabilidad, simplificó la sustitución de componentes y redujo el impacto de cambios en librerías externas.

## 5.2. Gestión de los datos y almacenamiento de resultados

Uno de los puntos críticos del desarrollo fue la elección de un formato común para el intercambio de información entre módulos. Para este propósito se optó por utilizar el formato **Parquet** [20], un formato de almacenamiento en columnas ampliamente utilizado en entornos de análisis de datos y *big data*.

La elección de Parquet frente a alternativas más simples como **Comma-Separated Values (CSV)** o formatos binarios genéricos se basó en varios criterios. En primer lugar, Parquet ofrece un almacenamiento más eficiente en espacio como en tiempo de acceso, gracias a su organización en columnas y a los mecanismos de compresión integrados. Este aspecto resulta especialmente relevante en un proyecto que genera múltiples ejecuciones de modelos, cada una con diferentes configuraciones de hiperparámetros y métricas asociadas.

La persistencia se organizó en dos niveles:

- **data/ingestion**: datasets base (*issues, readmes, thesis, abstracts, metadatos*).
- **data/processing/<modelo>**: artefactos de entrenamiento y evaluación por modelo/dataset (temas, métricas, parámetros, mejores hiperparámetros y ensayos de optimización).

Este contrato explícito de ficheros permitió desacoplar ejecución y análisis: el módulo web trabaja en modo lectura sobre resultados ya calculados, mientras que el procesamiento puede relanzarse sin afectar a la interfaz.

Desde el punto de vista de la implementación, el formato Parquet se utilizó principalmente para almacenar:

- Los datos sin procesar, incluyendo los textos y cualquier metadato relevante.
- Los resultados de la ejecución de los modelos de temas, incluyendo la información asociada a los temas generados.
- Las métricas de evaluación obtenidas en cada ejecución.
- Los valores de los hiperparámetros utilizados durante los procesos de optimización.

### 5.3. Optimización de hiperparámetros y gestión de experimentos

La fase de experimentación se apoyó en Optuna [8] para la búsqueda de hiperparámetros. Frente a herramientas más genéricas como *GridSearchCV* de *scikit-learn*, Optuna no impone restricciones sobre la estructura del modelo ni sobre el flujo de entrenamiento, lo que facilita su integración con bibliotecas heterogéneas como LDA, BERTopic, FASTopic o Top2Vec. Esta independencia del *framework* resulta clave en un proyecto que combina modelos con paradigmas y requisitos muy diferentes.

Los resultados de cada ejecución, junto con los parámetros utilizados y las métricas calculadas, se almacenan en formato Parquet. Esta decisión facilita la trazabilidad de los experimentos, permite analizar ejecuciones pasadas y evita la repetición innecesaria de cálculos costosos desde el punto de vista computacional.

### 5.4. Despliegue y modos de ejecución

Durante la implementación se priorizó que el proyecto pudiera ejecutarse tanto en contextos de uso final como en entornos de desarrollo. Para ello se definió una orquestación centralizada con *Makefile* y Docker Compose [17].

El flujo de trabajo contempla tres modos, cuya arquitectura de decisión se ilustra en la Figura 5.1:

- **MODE=release**: uso de imágenes precompiladas en GHCR, orientado a ejecución rápida.

- **MODE=docker**: construcción local de imágenes para validar cambios de infraestructura.
- **MODE=local**: ejecución nativa en Python para depuración y desarrollo iterativo.




Figura 5.1: Diagrama conceptual de los modos de ejecución del proyecto.

Esta estrategia redujo fricción en la puesta en marcha y mejoró la reproducibilidad de resultados entre equipos y sistemas operativos.

## 5.5. Interfaz web y exploración de resultados

El módulo de visualización se implementó como un frontal web utilizando Streamlit [15]. Este componente consume directamente los resultados generados por el módulo de procesamiento y almacenados en ficheros Parquet, manteniendo así un acoplamiento mínimo entre ambos módulos.

La interfaz permite seleccionar modelos, explorar temas generados, visualizar métricas y analizar resultados de forma interactiva, tal y como se puede apreciar en la Figura 5.2. Esta decisión sustituye salidas estáticas por una herramienta más adecuada para un análisis exploratorio y facilita tanto la evaluación del sistema como la comprensión de los resultados obtenidos.

The screenshot displays the TFG Topics web interface. On the left is a sidebar with navigation options: 'Resumen ejecutivo' (selected), 'Exploración de tópicos', 'Mapa intertópico', 'Hiperparametrización', 'Comparativa de modelos', 'Idioma / Language' (set to ES), and 'Vista' (switched to 'Análisis Técnico Modelado de Temas'). The main content area is titled 'Análisis por modelo' and includes instructions to select a dataset and model. The 'abstracts' dataset and 'bertopic' model are selected. Below this, a 'Resumen ejecutivo' section shows 11 topics detected, 100 documents analyzed, and a coherence score of 0.597. A blue box highlights that the most prominent topic is T0 (11.1%) with a balanced thematic distribution. At the bottom, there are links for 'Exploración de tópicos' (with a sub-link for 'Tabla de tópicos') and 'Resumen de tópicos'.

TFG Topics

Deploy

### Análisis por modelo

Selecciona el conjunto de documentos y el modelo de tópicos para analizar sus resultados precomputados.

Selecciona un dataset: abstracts

Selecciona un modelo: bertopic

#### Resumen ejecutivo

| Tópicos detectados | Documentos anal... | Coherencia |
|--------------------|--------------------|------------|
| 11                 | 100                | 0.597      |

El tópico con mayor peso es T0 (11.1%), con distribución temática equilibrada.

#### Exploración de tópicos

Tabla de tópicos Wordcloud

#### Resumen de tópicos

Resumen textual de cada tópico mediante sus palabras clave más relevantes, ordenadas

Figura 5.2: Vista general de la interfaz interactiva desarrollada con Streamlit.



---

## 6. Trabajos relacionados

---

Este apartado sería parecido a un estado del arte de una tesis o tesina. En un trabajo final grado no parece obligada su presencia, aunque se puede dejar a juicio del tutor el incluir un pequeño resumen comentado de los trabajos y proyectos ya realizados en el campo del proyecto en curso.



---

## 7. Conclusiones y Líneas de trabajo futuras

---

El proyecto *TFG Topics* ha permitido diseñar e implementar una solución completa para el análisis temático cualitativo de memorias de **TFG** del grado en Ingeniería Informática de la Universidad de Burgos publicadas en GitHub, cubriendo todo el ciclo de vida del dato: ingesta, procesamiento, modelado y visualización.

A nivel de objetivos, se considera que el proyecto se ha cumplido de forma satisfactoria. Se ha construido un **Pipeline** modular con tres bloques bien diferenciados (*backend-ingestion*, *backend-processing* y *frontend-web*), con una arquitectura hexagonal en *backend* que facilita la mantenibilidad, la escalabilidad y la sustitución de componentes. Además, se ha definido un contrato de datos estable en formato Parquet, lo que mejora la trazabilidad experimental y desacopla claramente la generación de resultados de su consumo en la interfaz.

Desde el punto de vista experimental, se han entrenado y comparado cuatro enfoques de modelado de temas (**LDA**, BERTopic, Top2Vec y FAS-Topic) sobre cuatro fuentes textuales (*abstracts*, *issues*, *readmes* y cuerpo de las memorias). En el estado actual del proyecto, BERTopic ofrece la mejor coherencia en *issues*, *readmes* y cuerpo de las memorias, mientras que Top2Vec destaca en *abstracts*. Por su parte, LDA presenta un comportamiento competitivo en varios escenarios con un coste computacional significativamente menor. Este resultado evidencia un compromiso técnico relevante entre calidad semántica e inversión de recursos.

Estos resultados confirman que no existe un único modelo óptimo universal, sino que el rendimiento depende del tipo de texto analizado y de

su granularidad semántica. También se observa un compromiso claro entre calidad temática y coste computacional: los modelos basados en *embeddings* suelen mejorar la coherencia en varios escenarios, a costa de mayores tiempos de ejecución.

Como valoración crítica, identificamos tres limitaciones principales. En primer lugar, la evaluación se apoya mayoritariamente en métricas automáticas de coherencia, que no sustituyen una validación cualitativa experta. En segundo lugar, la heterogeneidad de los repositorios de origen introduce ruido documental y estructural que afecta a la estabilidad del modelado. En tercer lugar, algunos modelos basados en *embeddings* presentan costes de ejecución elevados, lo que condiciona la escalabilidad en corpus más grandes.

Además de los resultados cuantitativos, uno de los aportes principales del trabajo es haber construido una base software reutilizable: el sistema permite reejecutar fases de forma independiente, comparar configuraciones de manera homogénea y exponer resultados en una interfaz interactiva orientada a análisis exploratorio.

## 7.1. Líneas de trabajo futuras

Como evolución natural del proyecto, se plantean las siguientes líneas:

- Ampliar la evaluación con más métricas automáticas (por ejemplo, diversidad temática y estabilidad entre ejecuciones) y reforzar la validación humana con protocolos estandarizados de evaluación.
- Incorporar análisis temporal para estudiar la evolución de temáticas por curso académico y detectar tendencias emergentes.
- Mejorar la normalización lingüística en español (tratamiento de tecnicismos, acrónimos y expresiones de dominio) para aumentar la calidad semántica de los temas.
- Explorar variantes de modelado adicionales (modelos jerárquicos, dinámicos o nuevas configuraciones de *sentence-transformers*).
- Optimizar rendimiento mediante caché de *embeddings*, ejecución paralela y otras estrategias de reducción de coste computacional.
- Mejorar la interfaz de usuario: filtros académicos más ricos, exportación de informes para toma de decisiones y mejoras en accesibilidad para usuarios con necesidades especiales.

En definitiva, este TFG no solo entrega un prototipo funcional, sino una base técnica sólida y extensible sobre la que continuar investigación aplicada en analítica temática de documentación académica.



---

# Acrónimos

---

**AI** Artificial Intelligence. 5, 6

**ANN** Artificial Neural Networks. 10

**BERT** Bidirectional Encoder Representations from Transformers. 11, 13, 17

**BOW** Bag of Words. 9, 10, 11

**c-TF-IDF** Class-based Term Frequency-Inverse Document Frequency. 13, 17

**CSV** Comma-Separated Values. 28

**CU** Caso de Uso. 28

**DSR** Reconstrucción de Relaciones Semánticas Dual. 14

**ECTS** European Credit Transfer and Accumulation System. 8

**EPS** Escuela Politécnica Superior. 8

**ETP** Embedding Transport Plan. 14

**GHCR** GitHub Container Registry. 25, 29

**HDBSCAN** Hierarchical Density-Based Spatial Clustering of Applications with Noise. 11, 13, 14, 17

**LDA** Latent Dirichlet Allocation. 1, 4, 11, 12, 15, 16, 24, 29, 35

**NLP** Natural Language Processing. 5, 6, 8, 9, 23

**NLTK** Natural Language Tool Kit. 9

**SCRUM** Scrum Framework. 22

**TF** Term Frequency. 9

**TF-IDF** Term Frequency-Inverse Document Frequency. 9

**TFG** Trabajo de Fin de Grado. 1, 1, 3, 4, 5, 7, 8, 11, 18, 27, 35, 37

**UMAP** Uniform Manifold Approximation and Projection. 11, 13, 17

---

## Glosario

---

**Clustering** Proceso de agrupación automática de elementos en conjuntos homogéneos basados en medidas de similitud. [11](#), [13](#), [14](#), [17](#), [18](#)

**Coherencia** Métrica que evalúa la relación semántica entre los términos más representativos de un tema. [13](#), [15](#)

**Contenedorización** Técnica de virtualización ligera que encapsula una aplicación y sus dependencias en entornos aislados. [24](#)

**Control de versiones** Sistema que permite gestionar y registrar los cambios realizados sobre el código fuente a lo largo del tiempo. [22](#)

**Corpus** Conjunto estructurado de documentos utilizado como base para el análisis lingüístico o estadístico. [10](#), [15](#)

**Distancia euclidiana** Métrica que calcula la distancia geométrica directa entre dos puntos en un espacio vectorial. [10](#)

**Doc2Vec** Modelo de aprendizaje no supervisado que genera representaciones vectoriales de documentos completos. [17](#)

**Embeddings** Representación vectorial (numérica) del significado semántico de las palabras en un espacio multidimensional. [10](#), [11](#), [12](#), [13](#), [14](#), [15](#), [17](#), [18](#)

**FastText** Modelo de representaciones vectoriales que incorpora información de subpalabras para mejorar el tratamiento de palabras raras. [17](#)

**Framework** Estructura de software que proporciona una base sobre la que desarrollar aplicaciones de forma estandarizada. [23](#)

**Grid Search** Método de búsqueda de hiperparámetros que explora una parrilla de valores predefinida. 18

**Hiperparametrización** Proceso de configuración y ajuste de los hiperparámetros de un modelo para optimizar su rendimiento. 17

**K-Means** Algoritmo de clustering que agrupa datos en k conjuntos minimizando la distancia interna a los centroides. 17

**Kanban** Sistema visual de gestión del trabajo que permite controlar el flujo de tareas mediante columnas y estados. 22

**Lematización** Proceso de reducir las palabras a su forma canónica o lema. 5, 7, 8, 12

**Modelado de temas** Técnica de aprendizaje no supervisado para encontrar temas subyacentes en un corpus de documentos. 10

**Optimización Bayesiana** Método de búsqueda de hiperparámetros que utiliza un modelo probabilístico para encontrar los valores óptimos de forma eficiente. 18

**Pipeline** Cadena de procesamiento secuencial de datos estructurada en etapas, donde la salida de cada fase actúa como entrada de la siguiente. v, 6, 25, 35

**Preprocesamiento de texto** Conjunto de técnicas aplicadas a textos sin estructurar para limpiarlos, normalizarlos y prepararlos para su análisis automático. 8

**Random Search** Método de búsqueda de hiperparámetros que explora combinaciones aleatorias en un espacio de búsqueda. 18

**Reducción de dimensionalidad** Técnica que reduce el número de variables de un conjunto de datos preservando la información relevante. 11, 13, 14, 17, 18

**Similitud del coseno** Métrica que mide la similitud entre dos vectores calculando el coseno del ángulo que los separa. 10

**Sprint** Iteración temporal fija dentro de una metodología ágil en la que se desarrollan y revisan funcionalidades concretas. 22

**Stopwords** Palabras vacías con bajo valor semántico que se eliminan en la fase de preprocesamiento. 5, 8, 9, 12

**Tokenización** Proceso de dividir texto en unidades mínimas (tokens). 5, 6, 7, 8

**Ventana deslizante** Técnica que analiza secuencias de elementos consecutivos dentro de un texto para estudiar coocurrencias. 15



---

## Bibliografía

---

- [1] Fastopic: FASTopic. <https://github.com/bobxwu/fastopic>.
- [2] Gensim: Topic modelling for humans. [https://radimrehurek.com/gensim/auto\\_examples/index.html#documentation](https://radimrehurek.com/gensim/auto_examples/index.html#documentation).
- [3] Git - Reference. <https://git-scm.com/docs>.
- [4] LaTeX - A document preparation system. <https://www.latex-project.org/>.
- [5] Lda: Topic modeling with latent Dirichlet Allocation — lda documentation. <https://lda.readthedocs.io/en/latest/>.
- [6] NLTK :: Natural Language Toolkit. <https://www.nltk.org/>.
- [7] NumPy user guide — NumPy v1.26 Manual. <https://numpy.org/doc/1.26/user/index.html#user>.
- [8] Optuna - A hyperparameter optimization framework. <https://optuna.org/>.
- [9] Project Jupyter Documentation — Jupyter Documentation 4.1.1 alpha documentation. <https://docs.jupyter.org/en/latest/>.
- [10] Python 3.10.19 Documentation. <https://docs.python.org/3.10/>.
- [11] ¿Qué es la tokenización? Tipos, casos de uso, aplicación. <https://www.datacamp.com/blog/what-is-tokenization>.
- [12] ¿Qué es Visual Studio Code y cuáles son sus ventajas? | Blog de Arsys | Blog de Arsys. <https://www.arsys.es/blog/que-es-visual-studio-code-y-cuales-son-sus-ventajas>.

- [13] Quick Start - BERTopic. [https://maartengr.github.io/BERTopic/getting\\_started/quickstart/quickstart.html](https://maartengr.github.io/BERTopic/getting_started/quickstart/quickstart.html).
- [14] spaCy 101: Everything you need to know · spaCy Usage Documentation. <https://spacy.io/usage/spacy-101>.
- [15] Streamlit Docs. <https://docs.streamlit.io/>.
- [16] User Guide — pandas 2.3.3 documentation. [https://pandas.pydata.org/docs/user\\_guide/index.html](https://pandas.pydata.org/docs/user_guide/index.html).
- [17] Docker manuals. <https://docs.docker.com/manuals/>, 09:11:23 +0100 +0100.
- [18] Hexagonal Architecture and Clean Architecture (with examples). <https://dev.to/dyarleniber/hexagonal-architecture-and-clean-architecture-with-examples-48oi>, 2022.
- [19] PyCharm : Todo sobre el IDE de Python más popular. <https://datascientest.com/es/pycharm>, 2022.
- [20] Apache Parquet documentation. <https://parquet.apache.org/docs/>, 2026.
- [21] Agile Alliance. Agile 101 - What is Agile? <https://www.agilealliance.org/agile101/>, 2024. [En línea; consultado el 19-septiembre-2024].
- [22] Dimo Angelov. Top2Vec: Distributed Representations of Topics, 2020. <http://arxiv.org/abs/2008.09470>.
- [23] Dimo Angelov. Ddangelov/Top2Vec. <https://github.com/ddangelov/Top2Vec>, 2025.
- [24] John Atkinson-Abutridy. *Analítica textual*. Marcombo.
- [25] John Atkinson-Abutridy. *Grandes modelos de lenguaje. Conceptos, técnicas y aplicaciones*. Marcombo, 2023.
- [26] Aishwarya Bhangale. Introduction to Topic Modelling with LDA, NMF, Top2Vec and BERTopic, 2023. <https://medium.com/blend360/introduction-to-topic-modelling-with-lda-nmf-top2vec-and-bertopic-ffc3624d44e4>, [Internet, descargado 10-noviembre-2025].

- [27] Iqra Bismi. Topic modelling using LDA, 2023. <https://medium.com/@iqra.bismi/topic-modelling-using-lda-fe81a2a806e0>, [Internet, descargado 10-noviembre-2025].
- [28] David M Blei, Andrew Y Ng, and Michael I Jordan. Latent dirichlet allocation. *Journal of Machine Learning Research*, 3:993–1022, 2003.
- [29] Castillo-Velásquez Francisco Antonio Campos-Sánchez Jonathan Josefatz, Gonzalez-Gutierrez Fidel. Revisión Sistemática de Técnicas de Tokenización para la Clasificación de Información en Inteligencia Artificial. [https://virtual.cuautitlan.unam.mx/intar/memoriasceiaait/wp-content/uploads/sites/19/2024/12/24-Revision-Sistemática-de-Técnicas-de-Tokenización-\\_\\_para-la-Clasificación-de-Información-en-Inteligencia-\\_\\_Artificial-EDITADO.pdf](https://virtual.cuautitlan.unam.mx/intar/memoriasceiaait/wp-content/uploads/sites/19/2024/12/24-Revision-Sistemática-de-Técnicas-de-Tokenización-__para-la-Clasificación-de-Información-en-Inteligencia-__Artificial-EDITADO.pdf).
- [30] Gustavo Espíndola. ¿Qué son los embeddings y cómo se utilizan en la inteligencia artificial con python?, 2023. <https://gustavo-espindola.medium.com/qu%C3%A9-son-los-embeddings-y-c%C3%B3mo-se-utilizan-en-la-inteligencia-artificial-con-python-45b751ed86a5>.
- [31] Luca Franceschi, Michele Donini, Valerio Perrone, Aaron Klein, Cédric Archambeau, Matthias Seeger, Massimiliano Pontil, and Paolo Frasconi. Hyperparameter optimization in machine learning. *Foundations and Trends® in Machine Learning*, 18(6):1054–1201, 2025. <http://dx.doi.org/10.1561/22000000088>.
- [32] Thiyaneshwaran G. Top2vec for Topic Modeling and Semantic Similarity and Search, 2022. <https://medium.com/@ThiyaneshwaranG/top2vec-for-topic-modeling-and-semantic-similarity-and-search-77db82dda7d3>.
- [33] Lin Gan, Tao Yang, Yifan Huang, Boxiong Yang, Yami Yanwen Luo, Lui Wing Cheung Richard, and Dabo Guo. Experimental comparison of three topic modeling methods with lda, top2vec and bertopic. In *International Symposium on Artificial Intelligence and Robotics*, pages 376–391. Springer, 2023.
- [34] gewarren. Descripción de los tokens - .NET. <https://learn.microsoft.com/es-es/dotnet/ai/conceptual/understanding-tokens>.

- [35] Thomas L Griffiths and Mark Steyvers. Finding scientific topics. *PNAS*, 101(suppl 1):5228–5235, 2004.
- [36] Maarten Grootendorst. BERTopic: Neural topic modeling with a class-based TF-IDF procedure, 2022. <http://arxiv.org/abs/2203.05794>.
- [37] Mustapha Hankar, Mohammed Kasri, and Abderrahim Beni-Hssane. A comprehensive overview of topic modeling: Techniques, applications and challenges. *Neurocomputing*, 628:129638, 2025. <https://linkinghub.elsevier.com/retrieve/pii/S0925231225003108>.
- [38] Daniel Jurafsky and James H. Martin. *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models*. 3rd edition, 2025. <https://web.stanford.edu/~jurafsky/slp3/>.
- [39] Carlos López Nozal, Raúl Marticorena Sánchez, Juan José Rodríguez, and Andrés Bustillo Iglesias. Proceso de gestión de trabajos fin de carrera. In *Jornadas de Enseñanza Universitaria de la Informática*, pages 413–420. Jornadas de Enseñanza Universitaria de la Informática, 2009.
- [40] Madhurima Nath. Topic modeling algorithms, 2023. <https://medium.com/@m.nath/topic-modeling-algorithms-b7f97cec6005>, [Internet; descargado 10-noviembre-2025].
- [41] João Pedro. Understanding Topic Coherence Measures. <https://towardsdatascience.com/understanding-topic-coherence-measures-4aa41339634c/>, 2022.
- [42] Serhad Sarica and Jianxi Luo. Stopwords in technical language processing. *Plos one*, 16(8), 2021. <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0254937>.
- [43] Jasper Snoek, Hugo Larochelle, and Ryan P. Adams. Practical bayesian optimization of machine learning algorithms, 2012. <https://arxiv.org/abs/1206.2944>.
- [44] Dr Tiya Vaj. How to evaluate novel topic modeling method. <https://vtiya.medium.com/how-to-evaluate-novel-topic-modeling-method-104ad9684428>, 2023.
- [45] Xiaobao Wu, Thong Nguyen, Delvin Ce Zhang, William Yang Wang, and Anh Tuan Luu. FASTopic: Pretrained Transformer is a Fast, Adaptive, Stable, and Transferable Topic Model. *arXiv e-prints*, 2024.

- [46] James Jianqiao Yu. James-Yu/LaTeX-Workshop. <https://github.com/James-Yu/LaTeX-Workshop>, 2025.
- [47] Zube. Zube - project management for agile development. <https://zube.io>. Accessed: 2024-09-19.