



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática



**TFG del Grado en Ingeniería
Informática**

**Análisis de temas en Trabajos
Fin de Grado**



Presentado por Zeldan Javier Campos Cordero
en Universidad de Burgos — 27 de noviembre
de 2025

Tutor: Carlos López Nozal



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática



D. Carlos López Nozal, profesor del departamento de Ingeniería Informática, área de Lenguajes y Sistemas Informáticos.

Expone:

Que el alumno D. Zeldan Javier Campos Cordero, con DNI 55462889E, ha realizado el Trabajo final de Grado en Ingeniería Informática titulado Análisis de temas en Trabajos Fin de Grado.

Y que dicho trabajo ha sido realizado por el alumno bajo la dirección del que suscribe, en virtud de lo cual se autoriza su presentación y defensa.

En Burgos, 27 de noviembre de 2025

Vº. Bº. del Tutor:

D. Carlos López Nozal

Resumen

TFG topics es una aplicación que pretende realizar análisis temáticos cualitativos de los textos contenidos en las memorias de los trabajos finales de grado (TFG). Su objetivo es desarrollar una herramienta que permita a los docentes y estudiantes explorar e identificar tendencias en el contenido académico de dichos trabajos.

Para ello, se parte de un conjunto de datos creado con las memorias de TFG en formato LaTeX disponibles públicamente en GitHub. Sobre estos textos se lleva a cabo el procesamiento y modelado de temas utilizando diversos algoritmos como: **Latent Dirichlet Allocation (LDA)**, **Top2Vec**, **BERTopic** y **FASTopic**.

Este trabajo se centra en la implementación, comparación y evaluación de diferentes algoritmos de modelado de temas (**Topic Modeling**), con el fin de construir una herramienta que ayude a la gestión del conocimiento académico en el ámbito universitario.

Descriptores

Análisis temático, Topic Modeling, LDA, BERTopic, Top2Vec, FASTopic, TFG, Análisis de Datos, Procesamiento del Lenguaje Natural, Ingeniería Informática.

Abstract

TFG Topic is an application designed to perform qualitative thematic analysis of the texts contained in Bachelor's Thesis (TFG) reports. Its main goal is to develop a tool that enables teachers and students to explore and identify trends within the academic content of these works.

To achieve this, a dataset was built from TFG reports written in LaTeX format and publicly available on GitHub. These texts are processed and analyzed using various topic modeling algorithms, such as **Latent Dirichlet Allocation (LDA)**, **Top2Vec**, **BERTopic**, and **FASTopic**.

This work focuses on the implementation, comparison, and evaluation of different **Topic Modeling** algorithms, with the aim of building a tool that supports academic knowledge management within the university context.

Keywords

Topic Modeling, LDA, BERTopic, Top2Vec, FASTopic, TFG, Data Analysis, PNL, Computer Science.

Índice general

Índice general	iii
Índice de figuras	v
Índice de tablas	vi
1. Introducción	1
2. Objetivos del proyecto	3
2.1. Objetivo general	3
2.2. Objetivos específicos	3
2.3. Objetivos personales	4
3. Conceptos teóricos	5
3.1. Procesamiento de lenguaje natural	5
3.2. Preprocesamiento del textos	6
3.3. Representación del texto	9
3.4. Modelado de temas	10
3.5. Evaluación de modelos	13
3.6. Hiperparametrización de Modelos	15
3.7. Comparación de modelos	17
4. Técnicas y herramientas	19
5. Aspectos relevantes del desarrollo del proyecto	21
6. Trabajos relacionados	23

7. Conclusiones y Líneas de trabajo futuras	25
Bibliografía	27

Índice de figuras

Índice de tablas

3.1. Comparativa de las características de los algoritmos de modelado de tópicos.	17
--	----

1. Introducción

En el ámbito universitario anualmente se generan gran cantidad de documentos académicos que proporcionan una valiosa fuente de información. Especialmente las memorias de los **Trabajos de Fin de grado (TFG)** que poseen un alto valor y que forman parte fundamental del proceso formativo del estudiante, ya que permiten aplicar los conocimientos adquiridos durante la realización de los estudios de grado. Estas memorias contienen información sobre tendencias tecnológicas actuales, herramientas y investigaciones realizadas sobre distintas áreas de la informática. Sin embargo, resulta muy laborioso ubicar y extraer esta información ya que encuentra almacenada de manera dispersa en distinto repositorios y formatos.

Este trabajo tiene como finalidad el desarrollo de una aplicación para el análisis cualitativo de los textos contenidos en las memorias de TFG del grado en ingeniería Informática de la Universidad de Brugos. Esta herramienta permite el análisis, consulta, facilita la exploración, calculo de tendencias y comparación de trabajos a lo largo del tiempo partiendo de estos contenidos textuales. El conjunto de datos analizado se encuentra en formato $\text{\LaTeX}$ y se encuentra disponible en plataformas como GitHub, a estos datos se le aplicaran técnicas de modelado de temas utilizando distintos algoritmos de última generación, entre ellos **Latent Dirichlet Allocation (LDA)**, **Top2Vec**, **BERTopic** y **FASTopic**.

La aplicación resultante servirá como ayuda a la comunidad docente, investigadora e estudiantil para la exploración de la información académica. Además, se busca poner en práctica los conocimientos adquiridos y competencias durante la titulación.

Este proyecto se fundamenta en el uso de técnicas de modelado de temas. El modelado de temas es una tarea de aprendizaje no supervisado donde

se identifica la estructura temática de un grupo de documentos. Al utilizar estas técnicas es posible encontrar temas relevantes para organizar, buscar o comprender grandes cantidades de datos en formato de texto. Estos modelos se basan en el supuesto de cada documento puede explicarse como una mezcla de temas, donde cada tema es un grupo de términos que poseen una distribución de potabilidades.

Esta memoria se estructura de la siguiente manera: **Introducción**, se realiza una descripción inicial de el trabajo y su estructura; **Objetivos**, descripción de los objetivos generales y específicos que se pretenden alcanzar con la elaboración de este proyecto; **Conceptos teóricos**, en esta sección se presenta el marco teórico y conceptual que fundamenta el modelado de temas; **Técnicas y herramientas**, se describen las técnicas y herramientas utilizadas para la elaboración de la aplicación; **Aspectos relevantes del desarrollo del proyecto**, se presentan los desafíos superados durante la realización del proyecto, la metodología seguida y el diseño del sistema; **Trabajos relacionados**, se exponen otros proyectos y aplicaciones similares y se realizar una comparación con el proyecto actual; **Conclusiones y lineas de trabajo futura**, los resultados obtenidos y su análisis comparativo y se detallan las conclusiones y las posibles líneas de trabajo futuro.

2. Objetivos del proyecto

El presente Trabajo Fin de Grado tiene como objetivo principal el desarrollo de una aplicación capaz de realizar análisis temáticos cualitativos sobre los textos contenidos en las memorias de los Trabajos Fin de Grado (TFG) en Ingeniería Informática. Este proyecto busca aplicar técnicas de procesamiento del lenguaje natural y modelado de temas para facilitar la identificación de tendencias, temas recurrentes y áreas de investigación dentro del ámbito académico.

2.1. Objetivo general

Diseñar e implementar una aplicación que permita realizar análisis temáticos automáticos sobre memorias de TFG, utilizando diversos algoritmos de modelado de temas y evaluando su rendimiento en términos de coherencia y eficiencia.

2.2. Objetivos específicos

Para alcanzar el objetivo general, se plantean los siguientes objetivos específicos:

- **Recopilar y preparar los datos:** Crear un conjunto de datos a partir de memorias de TFG en formato $\text{\LaTeX}$ disponibles públicamente en GitHub, realizando el preprocesamiento necesario de los textos.
- **Implementar diferentes algoritmos de modelado de temas:** Investigar, aplicar y comparar métodos como **Latent Dirichlet Allocation (LDA)**, **Top2Vec**, **BERTopic** y **FASTopic**.

- **Evaluar el rendimiento de los modelos:** Medir y comparar la calidad de los temas generados utilizando métricas de coherencia temática.
- **Desarrollar una interfaz visual:** Diseñar una aplicación que permita la visualización de los resultados obtenidos.
- **Fomentar la gestión del conocimiento académico:** Promover el acceso y la reutilización del conocimiento generado por estudiantes en cursos anteriores, apoyando la investigación y la docencia.
- **Diseño de Arquitectura:** Diseñar e implementar una arquitectura de software modular que separe el motor de análisis de la capa de servicio, demostrando principios de Ingeniería de Software.
- **Gestión:** Utilizar herramientas y metodologías ágiles para planificar y implementar el proyecto. Utilizando Zube.io y GitHub.

2.3. Objetivos personales

- Crear una herramienta que sea de utilidad para la comunidad universitaria.
- Aplicar conocimientos adquiridos durante el grado, especialmente en el ámbito de Algoritmia, Desarrollo Avanzado de Sistemas Software y Minería de Datos.
- Consolidar conocimientos en las siguientes tecnologías: Python, git, docker.
- Mejorar habilidades de diseño de software, aplicación de buenas prácticas en desarrollo, testing de software y documentación.

3. Conceptos teóricos

A continuación se exponen conceptos teóricos que sientan las bases del proyecto, cubriendo desde el pre-procesamiento de texto hasta los algoritmos avanzados de modelado.

3.1. Procesamiento de lenguaje natural

El procesamiento de lenguaje natural (PLN, del inglés *Natural Language Processing*, NLP) es un campo de la Inteligencia Artificial (IA, del inglés *Artificial Intelligence*, AI) que se ocupa del análisis y la interpretación de textos que se encuentran en lenguaje humano. Utilizando estas técnicas los computadores pueden dar sentido a los datos contenidos en un conjunto de textos y así adquirir su conocimiento implícito [3].

NLP usa gran variedad de técnicas y modelos para analizar diferentes aspectos de los textos como la formación de palabras, el léxico, la sintaxis entre otros, con esto se pretende resolver problemas específicos relacionados con el lenguaje.

Entre las técnicas más usadas en NLP se encuentran la tokenización, lematización, eliminación de palabras vacías (del inglés *stopwords*), análisis sintáctico y extracción de información. En el contexto de este trabajo, las técnicas de NLP se utilizan para preparar los textos de las memorias de TFG, transformándolos en datos estructurados que puedan ser analizados mediante algoritmos de modelado de temas.

3.2. Preprocesamiento del textos

Antes de iniciar cualquier análisis los textos deben someterse a una serie de procesos para garantizar su limpieza, normalización y reducir dimensionada del vocabulario, con el fin de garantizar la calidad de los análisis resultantes.

Tokenización

La tokenización es un proceso fundamental dentro de el NLP y la AI, pues permite dividir el texto en unidades mínimas denominadas tokens, que pueden ser palabras, subpalabras, caracteres o unidades semánticas mas complejas [16]. Este proceso constituye la base para la mayoría de técnicas posteriores de análisis textual, ya que permite transformar cadenas de texto sin estructura en secuencias manejables por algoritmos computacionales.

La tokenización presenta una serie de problemas que son específicos de cada idioma. Por lo tanto, se requiere conocer el idioma del documento. La identificación del idioma mediante clasificadores que usan subsecuencias cortas de caracteres como características resulta muy efectiva, ya que la mayoría de los idiomas tienen patrones distintivos [1].

Tipos de Tokenización

Existen varios métodos comunes para realizar esta segmentación

Tokenización de Palabras El texto se divide en palabras individuales basándose en un delimitador, típicamente el espacio. Esta representación puede fallar con palabras compuestas o en idiomas sin espacios entre palabras (como el chino) [12].

Tokenización de Caracteres El texto se divide en caracteres individuales. Este método es útil para lenguajes con alfabetos complejos y permite al modelo manejar un rango más amplio de entradas, como palabras desconocidas o errores tipográficos [7, 12].

Tokenización de Subpalabras El texto se divide en subpalabras o fragmentos frecuentes de caracteres. Este método reduce la dimensionalidad y maneja eficazmente palabras raras y desconocidas [7, 12].

Tokenización de Espaciado Blanco Divide el texto basándose únicamente en los espacios, lo que resulta en una gestión incorrecta de puntuaciones o errores gramaticales [7].

En el contexto del análisis temático de TFG, la tokenización cumple varias funciones clave:

- Estandarizar los textos, permitiendo compararlos entre sí.
- Reduce ruido, al separar puntuación, símbolos o caracteres no relevantes.
- Facilita operaciones posteriores, como lematización, extracción de n-grams o cálculo de frecuencias.
- Mejora la precisión del modelado de tópicos, ya que una buena segmentación permite que los modelos identifiquen patrones semánticos coherentes.

En particular para este trabajo la tokenización presenta varios problemas o desafíos:

Tratamiento de compuestos palabras como “aprendizaje-servicio” deben decidirse como uno o dos tokens.

Abreviaturas universitarias “TFG”, “ETSI”, “ECTS”, etc., que pueden requerir reglas específicas.

Símbolos técnicos o matemáticos comunes en textos de informática.

Preservación del contexto eliminar puntuación puede afectar el significado y pérdida de contexto en algunos casos.

La tokenización es un proceso esencial y su correcta implementación afecta directamente la calidad del análisis temático y de los modelos posteriores, desde la extracción de palabras clave hasta el modelado de tópicos.

Lematización

La lematización es una técnica clave dentro del NLP que tiene como principal objetivo transformar o reducir las palabras a su forma canónica o lema, es decir, la forma bajo la cual se encontrarían en un diccionario. En muchas lenguas, el infinitivo se utiliza como lema para el verbo; por ejemplo, en español, dormir es el lema para la forma duermes [16].

El lema (*lemma*) se define como la forma de citación o forma base de una palabra. El concepto del lema es relevante para comprender la estructura del

significado. Un lema puede ser polisémico, es decir, puede tener múltiples sentidos. Cada aspecto individual del significado de un lema se denomina sentido de palabra (*word sense*). Por ejemplo, el lema mouse tiene al menos dos sentidos distintos: El roedor ó el dispositivo de control de cursor [16].

La lematización, al reducir las palabras a su forma base, asegura que un sistema de PLN trate variantes flexionales (como singular, plural o diferentes tiempos verbales) como la misma unidad, facilitando la generalización sobre el significado fundamental de la palabra.

Stopwords

Las palabras vacías (del inglés *stopwords*) es un termino que hace referencia a las palabras que deben ser eliminadas en la fase de preprocesamiento de texto para garantizar la precisión y eficiencia de las tareas de NLP. Estas palabras aparecen frecuentemente en muchos documentos, pero transmiten poca o nula información sobre la sección del texto al que pertenecen [19].

Al eliminar estas palabras que aportan baja información, se incrementa la significación estadística de los términos que si son relevantes y son verdaderamente importantes para la tarea. Ejemplos específicos de estas palabras son: cada, sobre, tal, el, la, entre otros [19].

Históricamente, se han realizado esfuerzos para identificar *stopwords* a partir de fuentes de conocimiento genéricas, como *Brown Corpus* o *20 newsgroup corpus*. Esto ha provocado la creación de listas genéricas que se utilizan en aplicaciones de NLP. Una de las listas más utilizadas es la distribuida con el paquete de Python NLTK (del inglés, *Natural Language Tool Kit*) [19].

Sin embargo, el lenguaje técnico utilizado en textos de ingeniería o tecnología se distingue del lenguaje común. El lenguaje técnico contiene su propio argot y palabras altamente frecuentes y poco informativas que no están presentes en las listas genéricas. No existe una lista estándar de *stopwords* para aplicaciones de procesamiento de lenguaje técnico. La adopción simple de listas genéricas deja muchos términos repetitivos y poco informativos específicos del dominio en los datos. Es por esto que el proceso de identificación de *stopwords* incluye una etapa posterior de evaluación humana por parte de expertos para confirmar que el término no contiene información sobre ingeniería y tecnología [19].

3.3. Representación del texto

Bolsa de palabras

La bolsa de palabras (del inglés *Bag of Words*, BOW) es una de las técnicas de representación de texto utilizada por distintas aplicaciones de NLP. Esta representación se basa en el conteo de palabras, ignorando el orden y la estructura gramatical del texto [15].

El método BOW implica la construcción de un vocabulario compuesto por todas las palabras únicas presentes en los documentos analizados y la definición de una métrica concreta para determinar el peso de cada término. Las métricas más empleadas para este fin son la frecuencia de términos (del inglés *term frequency*, TF), y la frecuencia inversa de documentos (del inglés *Term frequency-inverse document frequency*, TF-IDF) [15].

Una de las principales limitaciones de BOW es la pérdida de información contextual de los términos dentro de los documentos. Otro inconveniente de BOW es que no captura el significado de las palabras y trata todas las palabras como entidades independientes dentro del documento. Además, la vectorización mediante BW genera vectores dispersos de alta dimensión cuando se trabaja con corpus extensos, lo que incrementa la complejidad computacional y los requisitos de memoria. BOW no es capaz de gestionar los sinónimos, tratando palabras con un mismo significado como si estuvieran relacionadas [15].

Representaciones vectoriales

Debido a las limitaciones encontrados en otras formas de representación de texto como BOW, han surgido técnicas que buscan solucionar estos problemas, entre las cuales podemos encontrar a los *embeddings*. Los *embeddings* son una técnica de procesamiento de lenguaje natural que convierte el lenguaje humano en vectores matemáticos. Estos vectores son una representación del significado subyacente de las palabras, lo que permite que las computadoras procesen el lenguaje de manera más efectiva [8].

Los *embeddings* intentan solucionar el problema de la pérdida de contexto y semántica de BOW considerando el orden y la secuencia de aparición de cada término. Estos modelos se construyen sobre redes neuronales artificiales (del inglés *artificial neural networks*, ANN) y se entrenan con grandes cantidades de datos para capturar el significado contextual de una unidad léxica en función de las palabras que la rodean, y viceversa. Cada palabra en el espacio de *embeddings* se representa como un vector de números reales

con una dimensión predefinida. En un espacio de vectores de palabras, es posible identificar las palabras más similares a un término concreto del vocabulario utilizando métodos como la similitud del coseno o la distancia euclidiana. Estas técnicas permiten agrupar palabras relacionadas, clasificar textos, categorizar documentos y descubrir temas o tópicos latentes dentro del texto [15].

3.4. Modelado de temas

El modelado de temas (del inglés *Topic Modeling*) es una técnica muy utilizada con la cual podemos encontrar temas subyacentes dentro de un grupo de documentos que deseemos analizar. Esta sigue un enfoque estadístico y proporciona una forma de representar textos de una manera estructurada, lo que la hace ideal para analizar grandes conjuntos de datos textuales [5].

Dependiendo del algoritmo utilizado los términos se pueden obtener utilizando distintos enfoques como la bolsa de palabras (*Bag of words*), frecuencia de términos, frecuencia inversa de términos o basado en clases [17].

Podemos destacar la importancia del modelado de temas en los siguientes aspectos [5]:

Organización de la información permite categorizar los documentos en temas lo cual hace mas fácil el proceso de búsqueda.

Resumen permite capturar la esencia de la temática del documento.

Recomendación facilita realizar recomendaciones personalizadas para cada usuario usuarios

En este TFG nos centraremos en el uso de los siguiente modelos:

- Latent Dirichlet Allocation
- Top2Vec
- BERTopic
- FASTopic

Latent Dirichlet Allocation (LDA)

LDA (del inglés, *Latent Dirichlet Allocation*, LDA) es un modelo probabilístico que usa matrices de factorización basado en la distribución de Dirichlet. En este modelo se asume que cada documento expone una serie de temas y cada tema se caracteriza por una distribución de palabras basada en la frecuencia de aparición en el documento. Los resultados obtenidos al ejecutar el modelo no son deterministas, por lo que se puede obtener un resultado distinto en cada ejecución para el mismo *dataset* [17, 5].

LDA posee dos parámetros [4] que debemos ajustar para mejorar los resultados obtenidos:

- Numero de temas
- Factor de densidad del documento-tema
- Factor de densidad tema-palabra

Top2Vec

Top2Vec es un algoritmo de modelado de temas basado en *embeddings*, documentos y vectores de palabras. Este algoritmo asume que la semántica interna de los documentos es indicativo de que existe una temática común [10].

A diferencia de otros métodos como LDA, Top2Vec genera simultáneamente *embeddings* de documentos, *embeddings* de palabras y *embeddings* de tópicos, lo que le permite identificar agrupaciones semánticas de forma más natural y continua. Este enfoque se basa en la idea de que los documentos que tratan temas similares deben estar próximos entre sí en un espacio vectorial de alta dimensión. Mediante el uso de modelos de lenguaje basados en redes neuronales, Top2Vec representa documentos y palabras en un espacio semántico compartido, permitiendo descubrir tópicos como densidades locales o agrupaciones (del inglés *clusters*) de documentos [2].

Ventajas de Top2Vec [2]:

- No requiere preprocesamiento, ya que funciona bien sin necesidad de: eliminación de *stopwords*, realizar lematización, limpiar puntuación, filtrar términos raros, etc.
- No requiere elegir el numero de tópicos.

- Produce tópicos con alta coherencia semántica.
- Permite buscar documentos por similitud, identificar documentos mas representativos de un tópico.

BERTopic

BERTopic es un método de modelado de tópicos que combina *embeddings* semánticos, reducción de dimensionalidad y *clustering* para identificar temas en grandes colecciones de texto de manera automática y precisa [14]

BERTopic se basa en el uso de BERT (del inglés, *Bidirectional Encoder Representations from Transformers*, BERT) preentrenado para genera representaciones vectoriales de los documentos y temas. El funcionamiento de BERTopic se apoya en dos fases: la codificación de los documentos y el modelado de temas. En la primera etapa, cada texto se transforma en un vector mediante BERT. Posteriormente, se emplea el algoritmo HDBSCAN para agrupar estos vectores y así identificar los distintos temas. A partir de cada grupo, es posible extraer las palabras clave que describen su contenido [11].

BERTopic combina cuatro componentes principales:

- *Embeddings* (representaciones semánticas)
- Reducción de dimensionalidad (UMAP), una técnica que reduce las dimensiones de los *embeddings* manteniendo las relaciones importantes.
- *Clustering* basado en densidad (HDBSCAN), es un algoritmo que detecta “grupos naturales” en los datos.
- Representación final de tópicos (c-TF-IDF), método para identificar las palabras más representativas de cada tópico.

La principal ventaja de BERTopic es su capacidad para encontrar matices semánticos y manejar grandes volúmenes de información textual. Puede identificar significados complejos y relaciones contextuales con mayor precisión. Además, a diferencia de otros métodos, no es necesario fijar de antemano cuántos temas se generarán, ya que el algoritmo de *clustering* determina este número automáticamente [11].

FASTopic

FASTopic (*Fast, Adaptive, Stable and Transferable topic model*). Es un modelo que sigue el enfoque denominado DSR (Reconstrucción de Relaciones Semánticas Dual), este no utiliza redes neuronales y se basa en tres elementos: la representación vectorial de los documentos graneados por un transformador predeterminado, los vectores de temas y de palabras [22].

DSR captura dos tipos de relaciones semánticas: entre documentos y temas, y entre temas y palabras, interpretándolas como distribuciones que permiten descubrir los temas de manera ordenada y eficiente, eliminando la necesidad de estructuras complicadas. Para modelar estas relaciones, se propone además el *Embedding Transport Plan* (ETP), un mecanismo novedoso que, en lugar de emplear funciones *softmax* parametrizadas, regula estas relaciones como planes de transporte óptimo entre los *embeddings* de documentos, temas y palabras. Esto reduce el sesgo en las relaciones y permite obtener temas bien diferenciados y distribuciones más precisas [22].

FASTopic se basa en los siguientes pasos:

- Generación de *Embeddings* (representaciones semánticas).
- Reducción de dimensionalidad.
- *Clustering*, no se limitan a HDBSCAN, sino que permiten el uso de múltiples algoritmos de *clustering* que buscan eficiencia y escalabilidad.
- Extracción de palabras representativas del tópico.

FASTopic tiene como principales ventajas la capacidad de manejar documentos de gran tamaño si necesidad de utilizar mayor capacidad de procesamiento, no requiere limpieza extrema del texto y produce una calidad semántica similar a la de BERTopic cuando se usan buenos *embeddings*.

3.5. Evaluación de modelos

Evaluar la calidad del resultado de los modelos de tópicos es una parte esencial del proceso de análisis. Es importante verificar si los tópicos generados son coherentes, útiles y representativos para los textos.

La evaluación puede realizarse utilizando alguna de las siguientes técnicas:

- Utilizando métricas automáticas, que proporcionan valores numéricos objetivos.
- Evaluación humana o cualitativa, que revisa si los tópicos tienen sentido.
- Utilizando métricas híbridas, que combinan ambas aproximaciones.

Métricas automáticas

Las métricas permiten comparar el resultado de los modelos sin necesidad de intervención humana, las mas comunes son: perplexidad y coherencia.

Perplexidad

Es una medida utilizada en modelos probabilísticos como LDA. Indica que tan bien el modelo es capaz de predecir documentos no vistos. Cuanto mas baja mejor se considera el desempeño del modelo, implica que el modelo tiene una mayor capacidad para anticipar las palabras de textos que no han sido utilizados durante el entrenamiento.

Solo es útil para comparar versiones diferentes del mismo tipo de modelo probabilístico (LDA). No es adecuada para modelos basados en *embeddings* (BERTopic, Top2Vec, FASTopic).

Coherencia

Es una métrica que evalúa que tan relacionados están los términos de las palabras mas representativas de un tema. Esta métrica permite identificar cuantos temas son adecuados para un conjunto de datos determinado [18]

Los métodos más usados son:

- **C_V**: basada en similitud semántica.
- **UCI**: mide coocurrencias de palabras en ventanas deslizantes.
- **UMass**: calcula coocurrencias dentro del propio corpus.

Esta métrica funciona bien tanto en LDA como en BERTopic, Top2Vec o FASTopic.

Evaluación Humana

El investigador revisa la lista de términos que componen cada tópico y determina si son coherentes. En investigación cualitativa es habitual que varias personas evalúen los tópicos y se calcule el índice de acuerdo inter-evaluador. Esto ayuda a evitar que la evaluación dependa de la subjetividad de una sola persona [21]

3.6. Hiperparametrización de Modelos

Los hiperparámetros son valores configurados por el investigador antes de entrenar un modelo. Determinan el comportamiento del algoritmo, la calidad de los tópicos obtenidos y el tiempo de cómputo. Ajustarlos adecuadamente es esencial para obtener resultados óptimos en el análisis temático [6, 13].

Hiperparámetros en LDA

LDA es uno de los modelos más sensibles a su configuración.

Número de Tópicos (k)

Controla cuántos temas debe encontrar el modelo. Valores demasiado bajos generan tópicos demasiado generales, mientras que valores demasiado altos producen tópicos ruidosos o redundantes.

Parámetro α

Regula cuántos tópicos aparecen en cada documento. Valores altos implican documentos con muchos temas mezclados; valores bajos generan documentos dominados por pocos tópicos.

Parámetro β

Determina cuántas palabras componen cada tópico. Un valor alto genera temas más dispersos y un valor bajo produce tópicos más específicos.

Número de Iteraciones

Afecta la estabilidad del modelo. Más iteraciones proporcionan mejor convergencia a costa de un mayor tiempo de entrenamiento.

Hiperparámetros en BERTopic

BERTopic tiene hiperparámetros en varias etapas: embeddings, reducción dimensional (UMAP), clustering (HDBSCAN) y extracción de palabras mediante c-TF-IDF.

UMAP

Los hiperparámetros más relevantes son:

- **n_neighbors**: controla la influencia del vecindario local. Valores bajos encuentran temas más específicos.
- **n_components**: número de dimensiones finales.

HDBSCAN

Los ajustes más influyentes son:

- **min_cluster_size**: tamaño mínimo del grupo.
- **min_samples**: sensibilidad al ruido.

Hiperparámetros en Top2Vec

Top2Vec utiliza hiperparámetros principalmente en el modelo de embeddings (Doc2Vec, BERT o USE) y en configuraciones de UMAP y HDBSCAN, compartiendo muchos de los ajustes de BERTopic.

Hiperparámetros en Fastopic

Fastopic está optimizado para grandes volúmenes de datos y permite configurar:

- tipo de embeddings (BERT, FastText, etc.).
- número de clusters en métodos rápidos como K-Means.
- número de palabras clave extraídas por tópico.

Tanto la evaluación como la hiperparametrización de modelos de tópicos son procesos fundamentales para garantizar la calidad del análisis temático. Modelos como LDA requieren ajustes cuidadosos en parámetros

probabilísticos, mientras que modelos modernos como BERTopic, Top2Vec y Fastopic dependen más de configuraciones de embeddings, reducción de dimensionalidad y clustering. La combinación de métricas automáticas y evaluación humana proporciona la estrategia más robusta para obtener tópicos coherentes y útiles en contextos como el análisis de TFG.

Métodos de búsqueda de hiperparámetros

Existen diversas estrategias para ajustar hiperparámetros, con distintos niveles de complejidad y eficiencia:

- **Grid Search:** explora todas las combinaciones posibles dentro de un conjunto definido. Sin embargo, resulta poco eficiente cuando el número de hiperparámetros es elevado [9].
- **Random Search:** selecciona combinaciones aleatorias de hiperparámetros dentro de los rangos definidos. Ha demostrado ser más eficiente que la búsqueda exhaustiva en espacios de gran dimensionalidad [9].
- **Optimización Bayesiana:** construye un modelo probabilístico del rendimiento y selecciona nuevas combinaciones basadas en regiones prometedoras del espacio de búsqueda. Es una opción muy eficiente cuando las evaluaciones del modelo son costosas [20].

3.7. Comparación de modelos

Características	LDA	Top2Vec	BERTopic	FASTopic
Requiere indicar número de tópicos k	Sí	No	No	No
Uso de <i>embeddings</i>	No	Sí	Sí	Sí
Representación del texto	BOW	<i>embeddings</i> semánticos	<i>embeddings</i> contextuales	<i>embeddings</i> contextuales
Preprocesamiento necesario	Alto	Muy bajo	Moderado	Bajo
Coherencia de tópicos	Media	Muy Alta	Alta	Muy Alta
Coste computacional	Bajo	Alto	Alto	Alto
Interpretabilidad	Alta	Media	Media-Alta	Media

Tabla 3.1: Comparativa de las características de los algoritmos de modelado de tópicos.

4. Técnicas y herramientas

Esta parte de la memoria tiene como objetivo presentar las técnicas metodológicas y las herramientas de desarrollo que se han utilizado para llevar a cabo el proyecto. Si se han estudiado diferentes alternativas de metodologías, herramientas, bibliotecas se puede hacer un resumen de los aspectos más destacados de cada alternativa, incluyendo comparativas entre las distintas opciones y una justificación de las elecciones realizadas. No se pretende que este apartado se convierta en un capítulo de un libro dedicado a cada una de las alternativas, sino comentar los aspectos más destacados de cada opción, con un repaso somero a los fundamentos esenciales y referencias bibliográficas para que el lector pueda ampliar su conocimiento sobre el tema.

5. Aspectos relevantes del desarrollo del proyecto

Este apartado pretende recoger los aspectos más interesantes del desarrollo del proyecto, comentados por los autores del mismo. Debe incluir desde la exposición del ciclo de vida utilizado, hasta los detalles de mayor relevancia de las fases de análisis, diseño e implementación. Se busca que no sea una mera operación de copiar y pegar diagramas y extractos del código fuente, sino que realmente se justifiquen los caminos de solución que se han tomado, especialmente aquellos que no sean triviales. Puede ser el lugar más adecuado para documentar los aspectos más interesantes del diseño y de la implementación, con un mayor hincapié en aspectos tales como el tipo de arquitectura elegido, los índices de las tablas de la base de datos, normalización y desnormalización, distribución en ficheros³, reglas de negocio dentro de las bases de datos (EDVHV GH GDWRV DFWLYDV), aspectos de desarrollo relacionados con el WWW... Este apartado, debe convertirse en el resumen de la experiencia práctica del proyecto, y por sí mismo justifica que la memoria se convierta en un documento útil, fuente de referencia para los autores, los tutores y futuros alumnos.

6. Trabajos relacionados

Este apartado sería parecido a un estado del arte de una tesis o tesina. En un trabajo final grado no parece obligada su presencia, aunque se puede dejar a juicio del tutor el incluir un pequeño resumen comentado de los trabajos y proyectos ya realizados en el campo del proyecto en curso.

7. Conclusiones y Líneas de trabajo futuras

Todo proyecto debe incluir las conclusiones que se derivan de su desarrollo. Éstas pueden ser de diferente índole, dependiendo de la tipología del proyecto, pero normalmente van a estar presentes un conjunto de conclusiones relacionadas con los resultados del proyecto y un conjunto de conclusiones técnicas. Además, resulta muy útil realizar un informe crítico indicando cómo se puede mejorar el proyecto, o cómo se puede continuar trabajando en la línea del proyecto realizado.

Bibliografía

- [1] ¿Qué es la tokenización? Tipos, casos de uso, aplicación. <https://www.datacamp.com/blog/what-is-tokenization>.
- [2] Dimo Angelov. Top2Vec: Distributed Representations of Topics, 2020. <http://arxiv.org/abs/2008.09470>.
- [3] John Atkinson-Abutridy. *Analítica textual*. Marcombo.
- [4] Aishwarya Bhangale. Introduction to Topic Modelling with LDA, NMF, Top2Vec and BERTopic, 2023. <https://medium.com/blend360/introduction-to-topic-modelling-with-lda-nmf-top2vec-and-bertopic-ffc3624d44e4>, [Internet, descargado 10-noviembre-2025].
- [5] Iqra Bismi. Topic modelling using LDA, 2023. <https://medium.com/@iqra.bismi/topic-modelling-using-lda-fe81a2a806e0>, [Internet, descargado 10-noviembre-2025].
- [6] David M Blei, Andrew Y Ng, and Michael I Jordan. Latent dirichlet allocation. *Journal of Machine Learning Research*, 3:993–1022, 2003.
- [7] Castillo-Velásquez Francisco Antonio Campos-Sánchez Jonathan Josefatz, Gonzalez-Gutierrez Fidel. Revisión Sistemática de Técnicas de Tokenización para la Clasificación de Información en Inteligencia Artificial. https://virtual.cuautitlan.unam.mx/intar/memoriasceiaait/wp-content/uploads/sites/19/2024/12/24-Revision-Sistemica-de-Tecnicas-de-Tokenizacion-__para-la-Clasificacion-de-Informacion-en-Inteligencia-__Artificial-EDITADO.pdf.

- [8] Gustavo Espíndola. ¿Qué son los embeddings y cómo se utilizan en la inteligencia artificial con python?, 2023. <https://gustavo-espindola.medium.com/qu%C3%A9-son-los-embeddings-y-c%C3%B3mo-se-utilizan-en-la-inteligencia-artificial-con-python-45b751ed86a5>.
- [9] Luca Franceschi, Michele Donini, Valerio Perrone, Aaron Klein, Cédric Archambeau, Matthias Seeger, Massimiliano Pontil, and Paolo Frasconi. Hyperparameter optimization in machine learning. *Foundations and Trends® in Machine Learning*, 18(6):1054–1201, 2025. <http://dx.doi.org/10.1561/22000000088>.
- [10] Thiyaneshwaran G. Top2vec for Topic Modeling and Semantic Similarity and Search, 2022. <https://medium.com/@ThiyaneshwaranG/top2vec-for-topic-modeling-and-semantic-similarity-and-search-77db82dda7d3>.
- [11] Lin Gan, Tao Yang, Yifan Huang, Boxiong Yang, Yami Yanwen Luo, Lui Wing Cheung Richard, and Dabo Guo. Experimental comparison of three topic modeling methods with lda, top2vec and bertopic. In *International Symposium on Artificial Intelligence and Robotics*, pages 376–391. Springer, 2023.
- [12] gewarren. Descripción de los tokens - .NET. <https://learn.microsoft.com/es-es/dotnet/ai/conceptual/understanding-tokens>.
- [13] Thomas L Griffiths and Mark Steyvers. Finding scientific topics. *PNAS*, 101(suppl 1):5228–5235, 2004.
- [14] Maarten Grootendorst. BERTopic: Neural topic modeling with a class-based TF-IDF procedure, 2022. <http://arxiv.org/abs/2203.05794>.
- [15] Mustapha Hankar, Mohammed Kasri, and Abderrahim Beni-Hssane. A comprehensive overview of topic modeling: Techniques, applications and challenges. *Neurocomputing*, 628:129638, 2025. <https://linkinghub.elsevier.com/retrieve/pii/S0925231225003108>.
- [16] Daniel Jurafsky and James H. Martin. *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models*. 3rd edition, 2025. <https://web.stanford.edu/~jurafsky/slp3/>.

- [17] Madhurima Nath. Topic modeling algorithms, 2023. <https://medium.com/@m.nath/topic-modeling-algorithms-b7f97cec6005>, [Internet; descargado 10-noviembre-2025].
- [18] João Pedro. Understanding Topic Coherence Measures. <https://towardsdatascience.com/understanding-topic-coherence-measures-4aa41339634c/>, 2022.
- [19] Serhad Sarica and Jianxi Luo. Stopwords in technical language processing. *Plos one*, 16(8), 2021. <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0254937>.
- [20] Jasper Snoek, Hugo Larochelle, and Ryan P. Adams. Practical bayesian optimization of machine learning algorithms, 2012. <https://arxiv.org/abs/1206.2944>.
- [21] Dr Tiya Vaj. How to evaluate novel topic modeling method. <https://vtiya.medium.com/how-to-evaluate-novel-topic-modeling-method-104ad9684428>, 2023.
- [22] Xiaobao Wu, Thong Nguyen, Delvin Ce Zhang, William Yang Wang, and Anh Tuan Luu. FASTopic: Pretrained Transformer is a Fast, Adaptive, Stable, and Transferable Topic Model. *arXiv e-prints*, 2024.